Projeto 2: Quantização de Cores com Redes SOM e GNG

Disciplina: Introdução às Redes Neurais Artificiais

Autora: Aline Breda Kuster (RA: 168.495)

Repositório: `https://github.com/aline-kuster/Proj2`

---

1 Objetivo

Reduzir drasticamente a paleta de cores de uma imagem (compressão) usando aprendizado competitivo, comparando o SOM (topologia fixa em uma grade 2D) com o GNG (topologia que cresce e se adapta aos dados), e avaliando as redes pelo erro de quantização e pelo erro topológico.

2 Metodologia

2.1 Extração

Cada imagem é carregada em RGB e redimensionada (filtro Lanczos, mantendo a proporção) para no máximo 450 pixels de lado, para manter o treino viável. Todos os pixels são extraídos e normalizados, de modo que cada pixel vira uma amostra $\mathbf{x} = (R, G, B) \in [0, 1]^3$: a imagem passa a ser um conjunto de dados 3D. Foram usadas cinco imagens com características de cor bem diferentes:

Imagem	Conteúdo	Dimensão	Pixels	Cores distintas
`por_do_sol`	degradê laranja e silhuetas escuras	450×300	135 000	36 390
`campo`	céu azul, nuvens brancas e grama	450×299	134 550	38 124
`praia`	céu, mar verde-azulado e areia	300×450	135 000	61 180
`tintas`	tintas de todas as cores (arco-íris)	450×300	135 000	92 991
`arara`	arara azul e amarela, fundo desfocado	300×450	135 000	78 855

Tabela 1: Imagens utilizadas após o redimensionamento.

2.2 Treinamento

SOM. Grades 4×4, 8×8 e 16×16, treinadas com a biblioteca **XPySom** por 100 épocas (em cada época todos os pixels são apresentados à rede). Os pesos iniciais são pixels aleatórios da imagem; a vizinhança é gaussiana, $h_{ij} = \exp\big(-\|\mathbf{r}_i - \mathbf{r}_j\|^2 / 2\sigma(t)^2\big)$, com $\sigma(t)$ decaindo exponencialmente de σ_0 até σ_N.

A XPySom implementa o *batch SOM*: em vez de mover os pesos a cada pixel, ela acumula, ao longo do lote, a média dos pixels ponderada pela vizinhança e substitui os pesos por essa média,

$$\mathbf{w}_j \leftarrow \frac{\sum_k h_{c(\mathbf{x}_k)\,j}\ \mathbf{x}_k}{\sum_k h_{c(\mathbf{x}_k)\,j}}.$$

Como a taxa de aprendizado $\eta(t)$ multiplica o numerador e o denominador, ela se cancela e *não tem efeito* nesse algoritmo. Por isso, no SOM, o ajuste de hiperparâmetros foi feito na largura da vizinhança (σ_0 e σ_N), que é a "taxa" que controla quanto cada neurônio puxa os seus vizinhos. O projeto também inclui uma implementação própria do SOM online (`-som-impl propria`), em que $\eta(t)$ é usada.

GNG. Implementação própria seguindo Fritzke (1995), com redes de 16, 64 e 256 neurônios. A rede começa com 2 neurônios; a cada pixel, o vencedor s_1 e seus vizinhos topológicos são movidos em direção à amostra (taxas ε_b e ε_n), a aresta s_1–s_2 é criada ou tem a idade zerada, e arestas com idade maior que $a_{\max}$ são removidas. A cada λ iterações um neurônio é inserido entre o neurônio de maior erro acumulado e o seu vizinho de maior erro ($\alpha = 0{,}5$, $d = 0{,}995$). O treino dura 2 épocas ($\approx 270\,000$ iterações): a primeira parte serve para a rede crescer até o tamanho final e o restante para o ajuste fino.

Ajuste de hiperparâmetros. Para cada tamanho de rede foram testadas três configurações. A melhor (menor erro de quantização) é usada nas figuras.

Config.	SOM (XPySom)	GNG
A	$\sigma_0 = L/2$, $\sigma_N = 1{,}0$	$\varepsilon_b = 0{,}2$, $\varepsilon_n = 0{,}006$, $\lambda = 100$, $a_{\max} = 50$
B	$\sigma_0 = L/2$, $\sigma_N = 0{,}5$	$\varepsilon_b = 0{,}05$, $\varepsilon_n = 0{,}0006$, $\lambda = 100$, $a_{\max} = 50$
C	$\sigma_0 = L/4$, $\sigma_N = 1{,}0$	$\varepsilon_b = 0{,}2$, $\varepsilon_n = 0{,}006$, $\lambda = 300$, $a_{\max} = 100$

Tabela 2: Configurações testadas (L = lado da grade do SOM).

2.3 Inferência e reconstrução

Para cada pixel original encontra-se o neurônio vencedor (BMU), $c(\mathbf{x}) = \arg\min_i \|\mathbf{x} - \mathbf{w}_i\|$, e a cor do pixel é substituída pelos pesos $\mathbf{w}_{c(\mathbf{x})}$. Em seguida a matriz da imagem é reconstruída ($H \times W \times 3$), salva em `data/output/` e exibida na tela ao final da execução.

2.4 Métricas

- **Erro de quantização (EQ):** $\frac{1}{N}\sum_k \|\mathbf{x}_k - \mathbf{w}_{c(\mathbf{x}_k)}\|$ (distância média pixel–BMU, em RGB normalizado).
- **Erro topológico (ET):** fração de pixels cujo 1º e 2º BMU *não* são vizinhos – no SOM, adjacentes na grade (vizinhança-8); no GNG, ligados por uma aresta.
- **MSE** e **PSNR** (dB), como métricas extras de qualidade visual: $\mathrm{PSNR} = 10\log_{10}(255^2/\mathrm{MSE}_{8\,\mathrm{bits}})$.
- **Cores usadas:** quantos neurônios realmente viraram a cor de algum pixel.

3 Resultados

A imagem `por_do_sol` é usada como exemplo principal (com todas as figuras detalhadas); as tabelas completas das outras quatro imagens estão no Apêndice A.

Modelo	Rede	Config.	Cores	EQ	ET	MSE	PSNR (dB)	Tempo (s)
SOM	4x4	A	16	0.0368	0.0000	6.73e-04	31.73	4.7
SOM	4x4	B	16	0.0307	0.0000	4.57e-04	33.39	4.3
SOM	4x4	C	16	0.0414	0.3853	8.95e-04	30.46	4.2
SOM	8x8	A	64	0.0180	0.1178	1.65e-04	37.81	17.2
SOM	8x8	B	64	0.0158	0.1510	1.24e-04	39.01	17.2
SOM	8x8	C	64	0.0176	0.1070	1.60e-04	37.93	17.3
SOM	16x16	A	254	0.0093	0.1370	4.50e-05	43.37	57.9
SOM	16x16	B	255	0.0086	0.2063	3.66e-05	44.23	57.8
SOM	16x16	C	254	0.0094	0.1168	4.67e-05	43.23	57.4
GNG	16 neur.	A	16	0.0316	0.0068	4.94e-04	33.03	13.1
GNG	16 neur.	B	16	0.0308	0.0011	4.65e-04	33.31	13.1
GNG	16 neur.	C	16	0.0318	0.0027	4.96e-04	33.04	12.7
GNG	64 neur.	A	64	0.0159	0.0080	1.26e-04	38.98	13.7
GNG	64 neur.	B	64	0.0156	0.0016	1.16e-04	39.29	13.8
GNG	64 neur.	C	64	0.0158	0.0007	1.26e-04	38.93	13.6
GNG	256 neur.	A	256	0.0086	0.0088	3.71e-05	44.19	16.7
GNG	256 neur.	B	256	0.0087	0.0042	3.56e-05	44.35	16.6
GNG	256 neur.	C	256	0.0085	0.0041	3.76e-05	44.12	15.9

Tabela 3: Todas as execuções na imagem `por_do_sol` (EQ = erro de quantização, ET = erro topológico).

Neurônios	EQ SOM	EQ GNG	ET SOM	ET GNG	PSNR SOM	PSNR GNG
16	0.0307	0.0308	0.0000	0.0011	33.39	33.31
64	0.0158	0.0156	0.1510	0.0016	39.01	39.29
256	0.0086	0.0085	0.2063	0.0041	44.23	44.12

Tabela 4: Comparação direta SOM × GNG na `por_do_sol`, com o mesmo número de neurônios (melhor configuração de cada).

	16 neurônios		64 neurônios		256 neurônios	
Imagem	SOM	GNG	SOM	GNG	SOM	GNG
`por_do_sol`	33,39	33,31	39,01	39,29	44,23	44,12
`campo`	30,58	31,17	37,28	37,86	43,12	43,01
`praia`	29,16	29,29	35,14	35,36	39,95	39,80
`tintas`	22,84	23,08	28,93	28,96	33,84	34,08
`arara`	26,21	26,04	31,85	31,77	36,44	36,10
Média	**28,44**	**28,58**	**34,44**	**34,65**	**39,52**	**39,42**

Tabela 5: PSNR (dB) da melhor configuração de cada rede, nas cinco imagens.

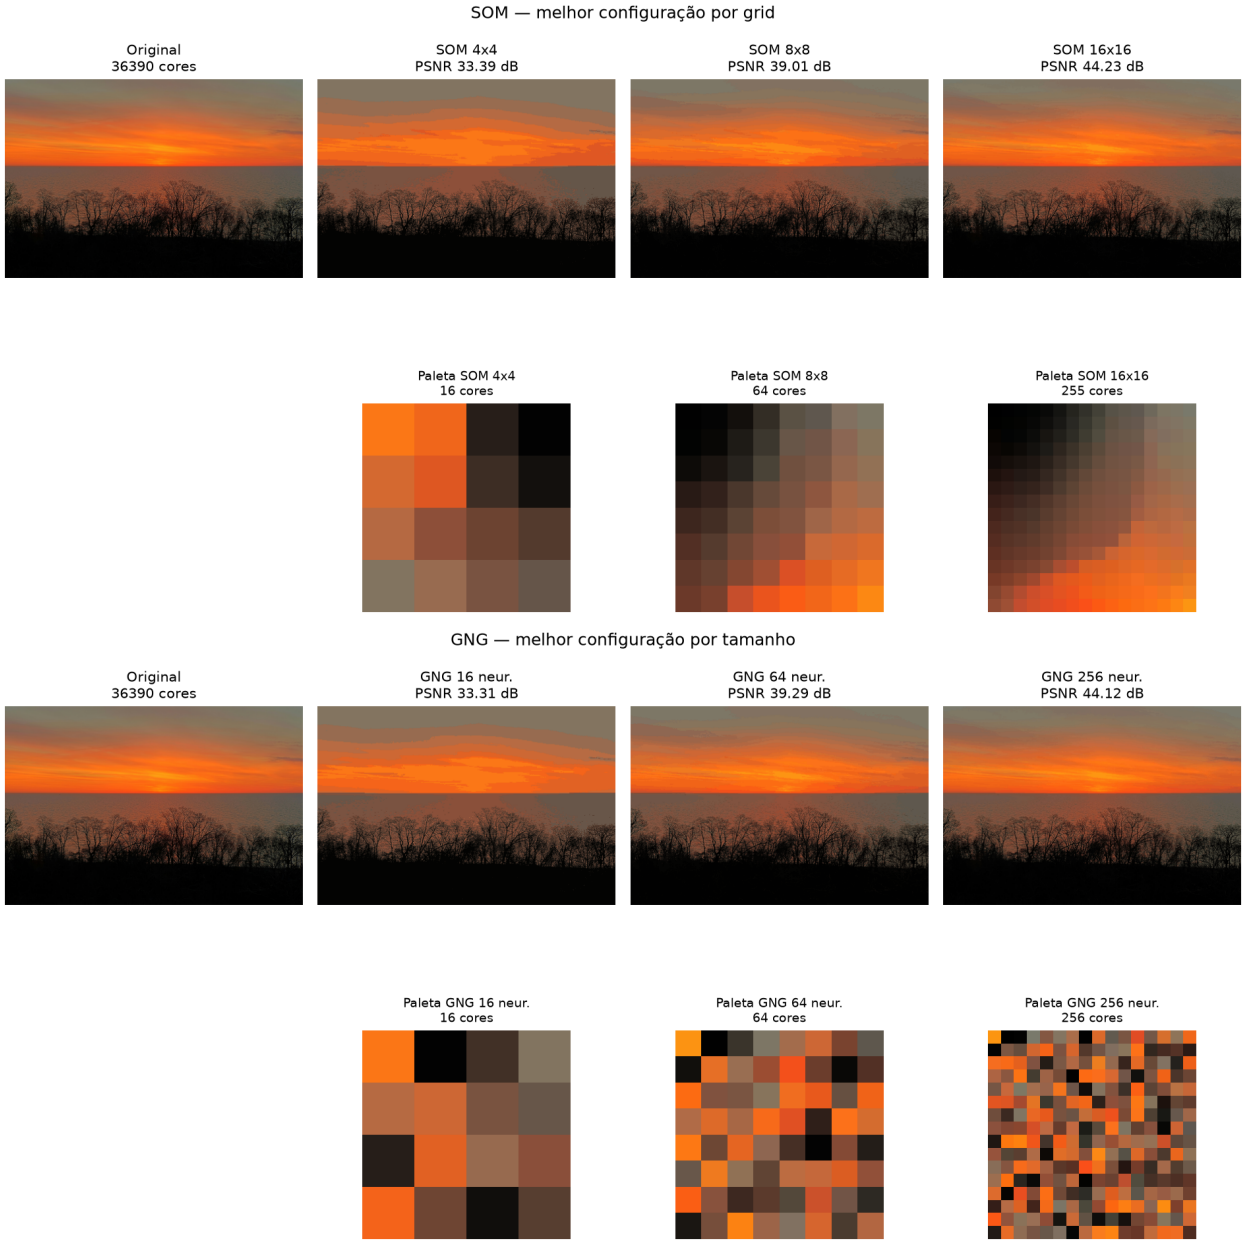


Figura 1: `por_do_sol`: imagens reconstruídas com a melhor configuração de cada rede e as paletas aprendidas. Na paleta do SOM os pesos estão na posição da grade (cores parecidas ficam vizinhas); na do GNG, na ordem em que os neurônios foram inseridos.

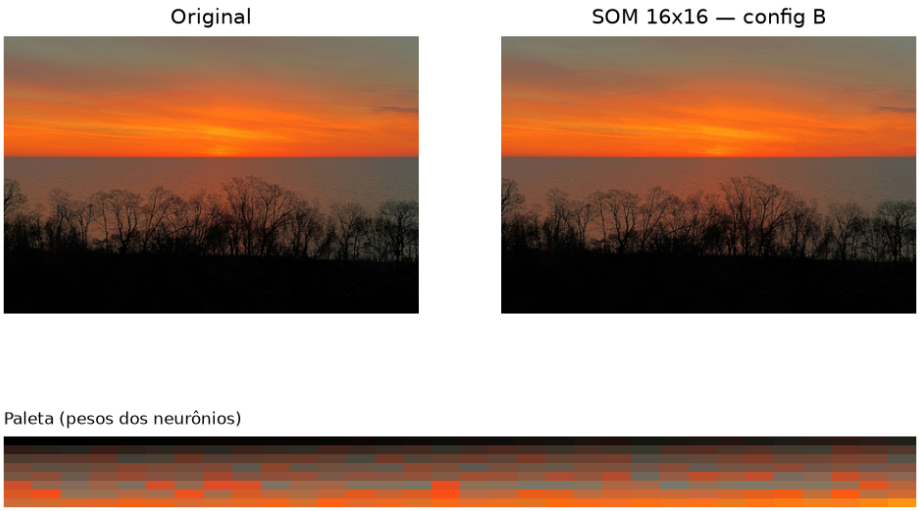


Figura 2: SOM 16×16: original, imagem quantizada e paleta extraída.

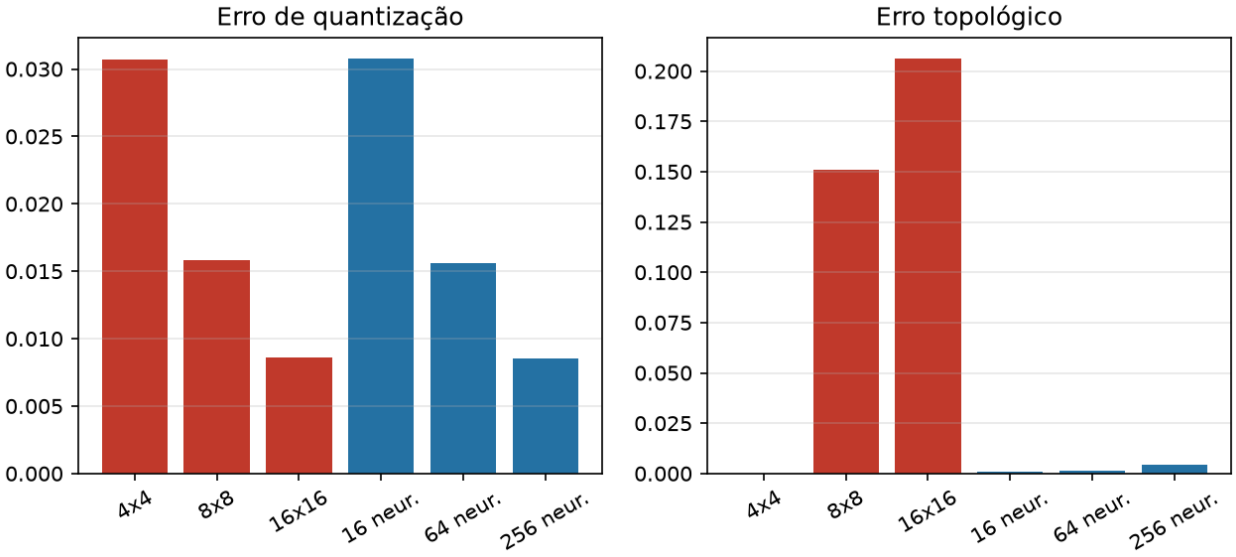
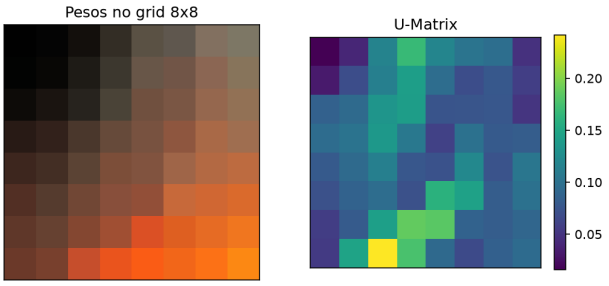
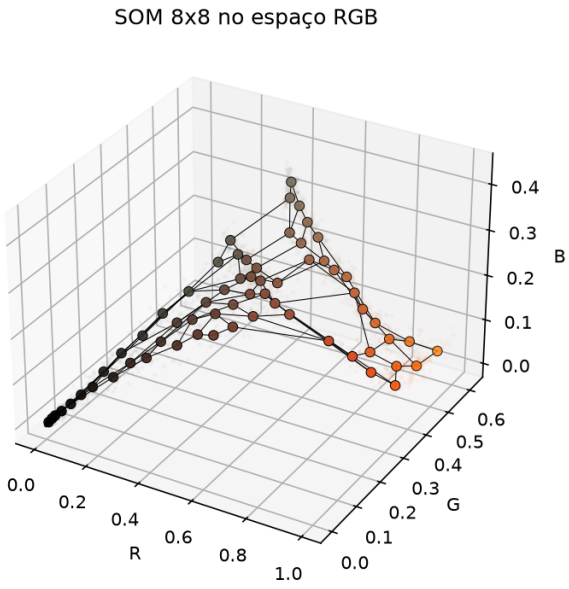


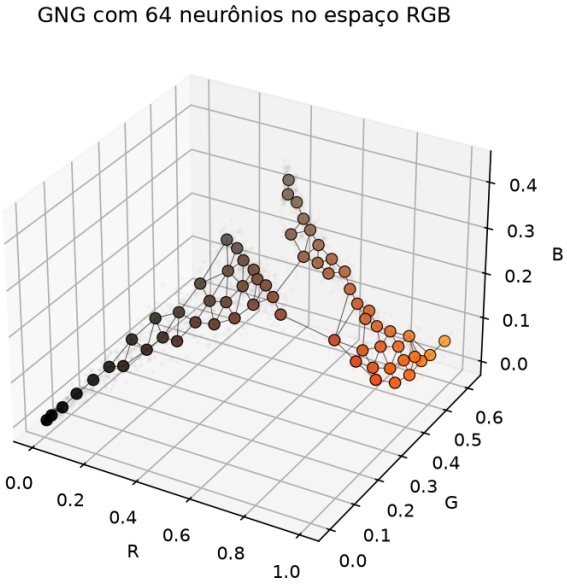
Figura 3: Erros da melhor configuração por rede na `por_do_sol` (vermelho: SOM; azul: GNG).



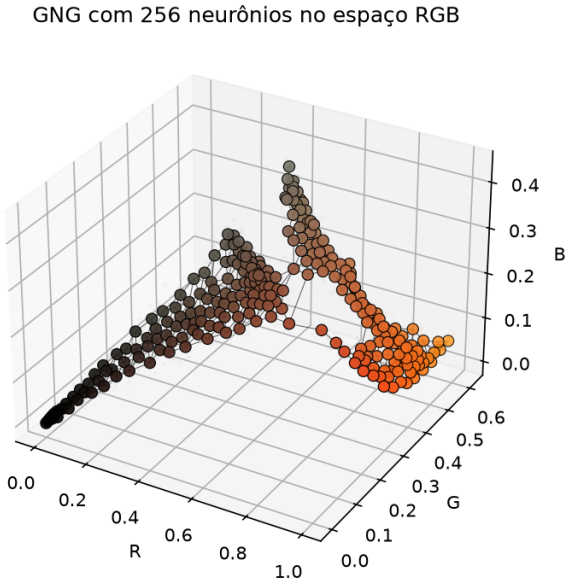
(a) SOM 8×8: pesos na grade e U-Matrix.



(b) SOM 8×8 no espaço RGB.



(c) GNG com 64 neurônios no espaço RGB.



(d) GNG com 256 neurônios no espaço RGB.

Figura 4: Topologia aprendida pelas redes (`por_do_sol`). As cores da imagem formam praticamente uma "curva" no espaço RGB, do preto ao laranja, com um ramo de tons acinzentados.

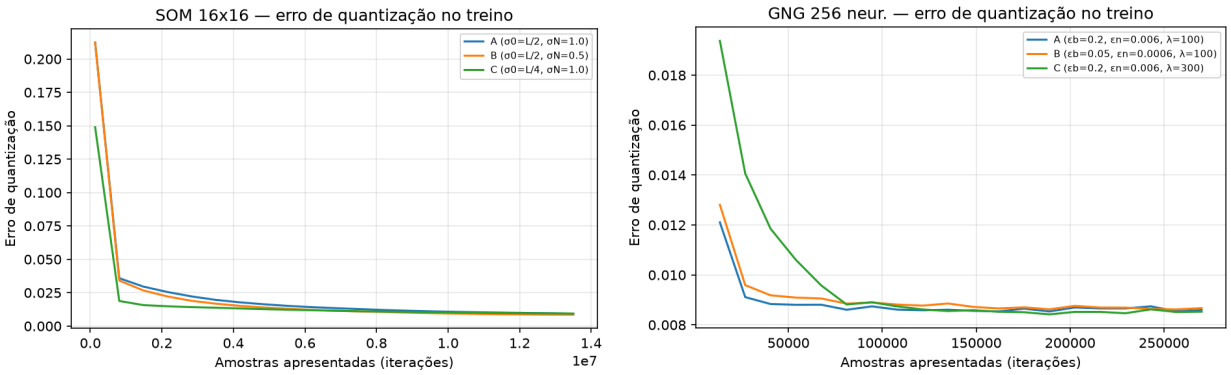


Figura 5: Erro de quantização ao longo do treino para as três configurações (`por_do_sol`).

4 Discussão

Tamanho da rede. Nos dois modelos, aumentar o número de neurônios reduz o erro de quantização aproximadamente pela metade a cada salto (`por_do_sol` – SOM: 0,031 → 0,016 → 0,009; GNG: 0,031 → 0,016 → 0,009) e aumenta o PSNR médio em cerca de 5–6 dB (Tabela 5). Com 16 cores o degradê do céu vira *faixas* bem visíveis (posterização); com 64 elas ficam suaves; com 256 a imagem é praticamente indistinguível da original, usando menos de 1% das cores distintas.

Dificuldade de cada imagem. A qualidade depende de quão espalhadas estão as cores no espaço RGB. O `por_do_sol` foi a imagem mais fácil (44 dB com 256 cores): suas cores ficam ao longo de uma "curva" do preto ao laranja, que poucos neurônios conseguem cobrir. A `tintas` foi a mais difícil (34 dB com 256 cores e erro de quantização mais de 3 vezes maior): ela tem quase 93 mil cores distintas, com matizes saturados espalhados por todo o cubo RGB, então cada neurônio precisa representar uma região muito maior. A `arara` ficou no meio-termo (36 dB): tem muitas cores, mas concentradas em poucos grupos (azul, amarelo, verde do fundo e preto/branco do rosto).

SOM × GNG: qualidade da reconstrução. Comparando a melhor configuração de cada modelo, os dois praticamente empatam: a diferença de PSNR nunca passa de 0,6 dB e as médias ficam dentro de 0,25 dB (Tabela 5) – diferença imperceptível a olho nu. Em geral o GNG foi um pouco melhor com 16 e 64 neurônios e o SOM com 256, sempre por margens pequenas (na `arara`, o SOM ficou levemente à frente nos três tamanhos). Esse empate, porém, só acontece porque a melhor configuração do SOM foi sempre a B, com vizinhança final pequena ($\sigma_N = 0{,}5$). Com $\sigma_N = 1{,}0$ (configurações A e C), o GNG tem erro de quantização menor que o SOM em todos os tamanhos e nas cinco imagens (por exemplo, `tintas` com 16 neurônios: 0,106 no GNG contra 0,124 no SOM A).

SOM × GNG: preservação topológica. Aqui a diferença é grande. Na melhor configuração, o erro topológico do GNG ficou sempre abaixo de 0,015, enquanto o do SOM chegou a 0,21 – na maioria dos casos, mais de 10 vezes maior. No GNG as arestas são criadas justamente entre o 1º e o 2º BMU (regra de Hebb competitiva), então a topologia da rede acompanha a distribuição real das cores. No SOM a topologia é imposta: uma grade 2D precisa se "dobrar" para cobrir a nuvem de cores, e cada dobra cria regiões em que o 2º BMU fica longe na grade. A exceção são redes pequenas em imagens "simples": no `por_do_sol` com 4×4, o SOM teve erro topológico zero, porque com poucos neurônios a grade consegue se estender sobre a curva de cores sem se dobrar.

O compromisso entre os dois erros no SOM. A configuração B mostra bem esse compromisso. Com $\sigma_N = 0{,}5$, no fim do treino a vizinhança efetiva quase desaparece e o batch SOM passa a se comportar como um k-means: cada neurônio se ajusta ao seu grupo de pixels sem ser puxado pelos vizinhos. Isso reduz o erro de quantização – B foi a melhor em todas as 15 combinações de imagem e tamanho – mas desorganiza o mapa: B teve o maior erro topológico em 11 dos 15 casos. Com $\sigma_N = 1{,}0$ (config. A), o mapa fica mais ordenado (erro topológico menor que o de B em 13 dos 15 casos), mas os neurônios são puxados para regiões intermediárias entre grupos de cor, o que piora a quantização. Ou seja, no SOM não dá para ter os dois ao mesmo tempo; o GNG chega ao mesmo erro de quantização sem abrir mão da topologia.

Outros hiperparâmetros.

- **SOM, σ_0 menor (config. C):** começar com uma vizinhança menor ($\sigma_0 = L/4$) piorou, em relação à config. A, o erro de quantização em 10 e o erro topológico em 12 dos 15 casos. Com pouca vizinhança no início, a grade não chega a se "desdobrar" sobre todas as cores antes de começar o ajuste fino, e algumas torções ficam congeladas (no `por_do_sol` 4×4, o ET chegou a 0,39). Um σ_0 grande é importante para a organização global do mapa.

- **GNG, taxas menores (config. B):** deram o menor erro de quantização em 10 dos 15 casos: depois que a rede termina de crescer, passos menores deixam os neurônios se acomodarem com mais precisão, em vez de ficarem "pulando" entre pixels.
- **GNG, mudanças mais lentas preservam a topologia:** o menor erro topológico foi sempre de uma das configurações B (taxas menores) ou C (λ maior). Em ambas a rede muda mais devagar, então as arestas têm tempo de se formar entre os neurônios certos.

Uso dos neurônios. Na maioria dos casos todos os neurônios viraram a cor de algum pixel. As exceções mais fortes aparecem no `campo`, que tem poucas cores bem separadas (azul, branco e verde): o GNG B usou só 59 de 64 e 214 de 256 neurônios. Com taxas pequenas, neurônios inseridos em regiões vazias entre esses grupos se movem muito pouco e nunca chegam a vencer nenhum pixel. No SOM 16×16 também sobram alguns neurônios (252–254 no `campo` e 245–248 na `tintas`): por causa da vizinhança, alguns ficam "presos" entre grupos de cor, em regiões onde não há pixels.

5 Conclusão

As duas redes conseguem comprimir a paleta de dezenas de milhares de cores para 16–256 cores mantendo boa qualidade visual, e com 256 neurônios o resultado é praticamente indistinguível da imagem original. A dificuldade da tarefa depende de quão espalhadas estão as cores da imagem: um pôr do sol (cores ao longo de uma curva) é muito mais fácil de quantizar que uma imagem com todas as cores do arco-íris. Na qualidade da reconstrução, o SOM só alcança o GNG quando a vizinhança final é reduzida, e aí perde a organização do mapa; o GNG obtém o mesmo erro de quantização preservando a topologia muito melhor, sendo a escolha mais adequada para a compressão em si. O SOM, por outro lado, entrega uma paleta organizada em uma grade 2D (cores parecidas lado a lado), útil quando se quer visualizar ou indexar o espaço de cores. Em ambos, os hiperparâmetros controlam o equilíbrio entre representar bem os dados (EQ) e preservar a vizinhança (ET).

A Resultados nas outras imagens

Campo

Modelo	Rede	Config.	Cores	EQ	ET	MSE	PSNR (dB)	Tempo (s)
SOM	4x4	A	15	0.0501	0.0945	1.27e-03	28.97	4.9
SOM	4x4	B	15	0.0421	0.0068	8.74e-04	30.58	4.9
SOM	4x4	C	16	0.0565	0.1612	1.56e-03	28.05	4.9
SOM	8x8	A	63	0.0202	0.0376	2.71e-04	35.66	18.1
SOM	8x8	B	62	0.0183	0.0553	1.86e-04	37.28	18.3
SOM	8x8	C	63	0.0209	0.0515	2.82e-04	35.48	18.0
SOM	16x16	A	252	0.0105	0.0990	6.22e-05	41.96	58.4
SOM	16x16	B	254	0.0098	0.1652	4.75e-05	43.12	57.4
SOM	16x16	C	253	0.0106	0.1684	6.64e-05	41.69	59.9
GNG	16 neur.	A	16	0.0402	0.0001	8.00e-04	30.98	14.1
GNG	16 neur.	B	16	0.0395	0.0028	7.61e-04	31.17	14.9
GNG	16 neur.	C	16	0.0402	0.0001	7.98e-04	30.98	13.4
GNG	64 neur.	A	64	0.0178	0.0030	1.62e-04	37.86	15.5
GNG	64 neur.	B	59	0.0188	0.0031	1.65e-04	37.80	13.9
GNG	64 neur.	C	64	0.0179	0.0028	1.69e-04	37.69	13.3
GNG	256 neur.	A	256	0.0101	0.0089	4.87e-05	43.01	16.0
GNG	256 neur.	B	214	0.0112	0.0027	5.59e-05	42.43	15.9
GNG	256 neur.	C	256	0.0101	0.0066	5.06e-05	42.86	15.4

Tabela 6: Imagem `campo`.

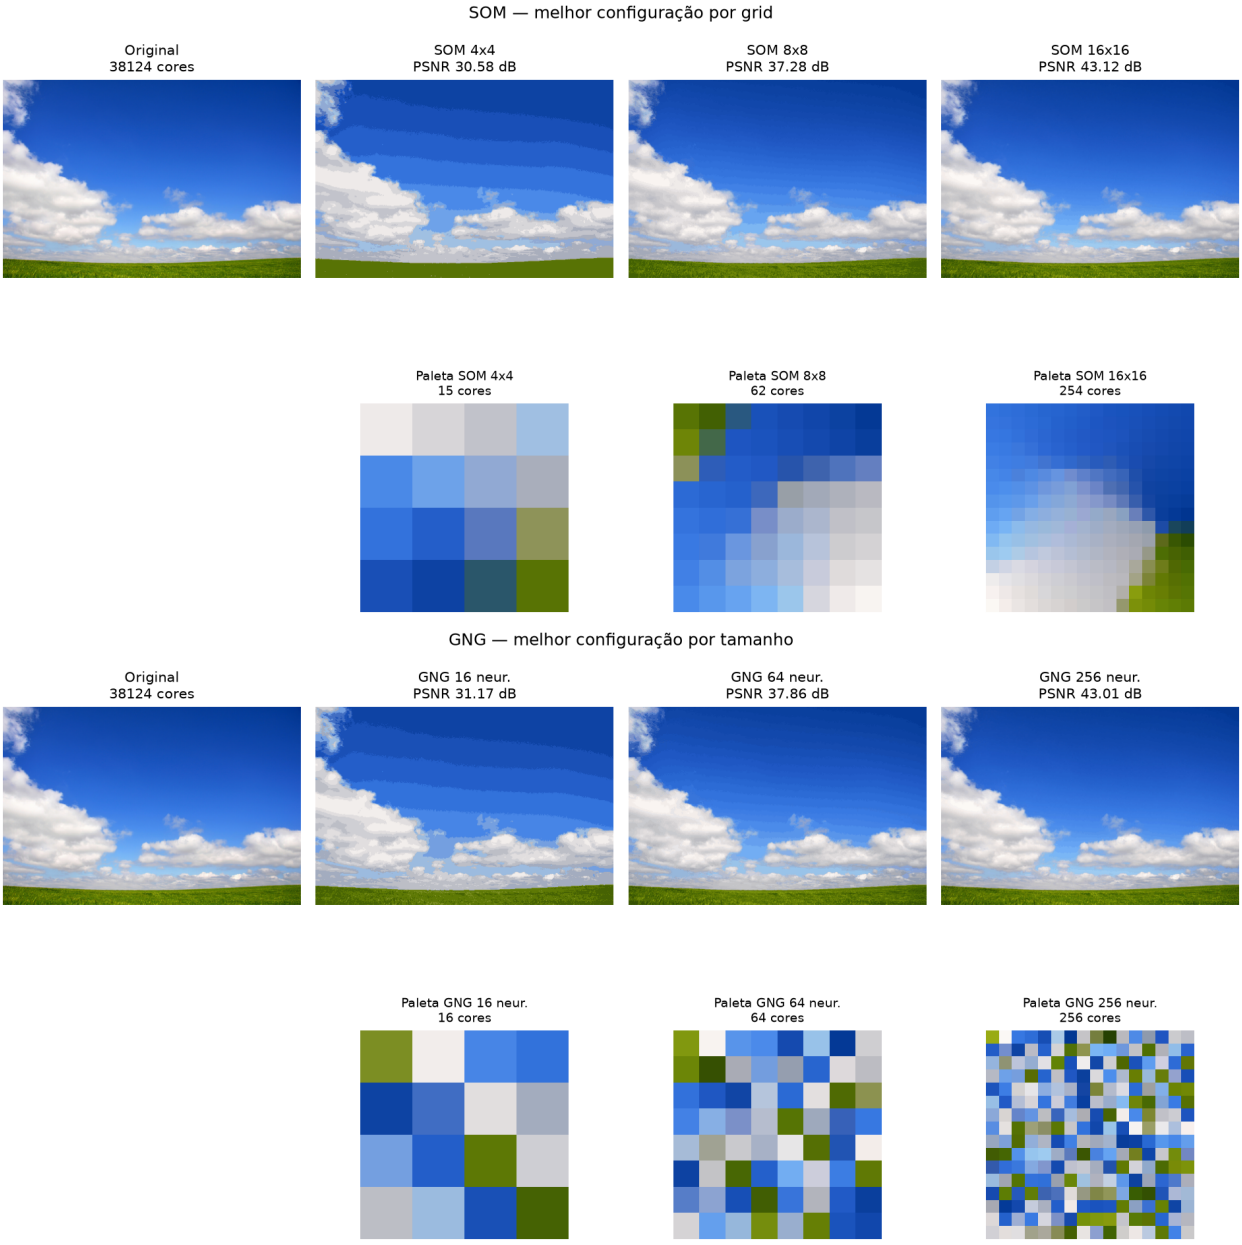


Figura 6: Reconstruções da imagem `campo`.

Praia

Modelo	Rede	Config.	Cores	EQ	ET	MSE	PSNR (dB)	Tempo (s)
SOM	4x4	A	16	0.0613	0.0000	1.94e-03	27.12	4.8
SOM	4x4	B	16	0.0521	0.0466	1.21e-03	29.16	4.7
SOM	4x4	C	16	0.0599	0.0237	1.75e-03	27.59	4.7
SOM	8x8	A	64	0.0287	0.0200	4.13e-04	33.83	17.1
SOM	8x8	B	64	0.0257	0.0661	3.05e-04	35.14	17.0
SOM	8x8	C	64	0.0288	0.0258	4.34e-04	33.60	17.1
SOM	16x16	A	254	0.0156	0.0172	1.23e-04	39.05	57.2
SOM	16x16	B	256	0.0145	0.0697	9.99e-05	39.95	56.5
SOM	16x16	C	254	0.0155	0.0205	1.22e-04	39.09	56.4
GNG	16 neur.	A	16	0.0542	0.0014	1.27e-03	28.96	12.7
GNG	16 neur.	B	16	0.0517	0.0036	1.18e-03	29.29	12.6
GNG	16 neur.	C	16	0.0551	0.0009	1.32e-03	28.81	12.5
GNG	64 neur.	A	64	0.0265	0.0079	3.19e-04	34.96	13.6
GNG	64 neur.	B	64	0.0257	0.0080	2.90e-04	35.36	13.6
GNG	64 neur.	C	64	0.0267	0.0028	3.21e-04	34.91	13.3
GNG	256 neur.	A	256	0.0152	0.0090	1.04e-04	39.80	16.3
GNG	256 neur.	B	252	0.0155	0.0061	1.03e-04	39.81	16.3
GNG	256 neur.	C	256	0.0153	0.0075	1.05e-04	39.73	15.6

Tabela 7: Imagem `praia`.

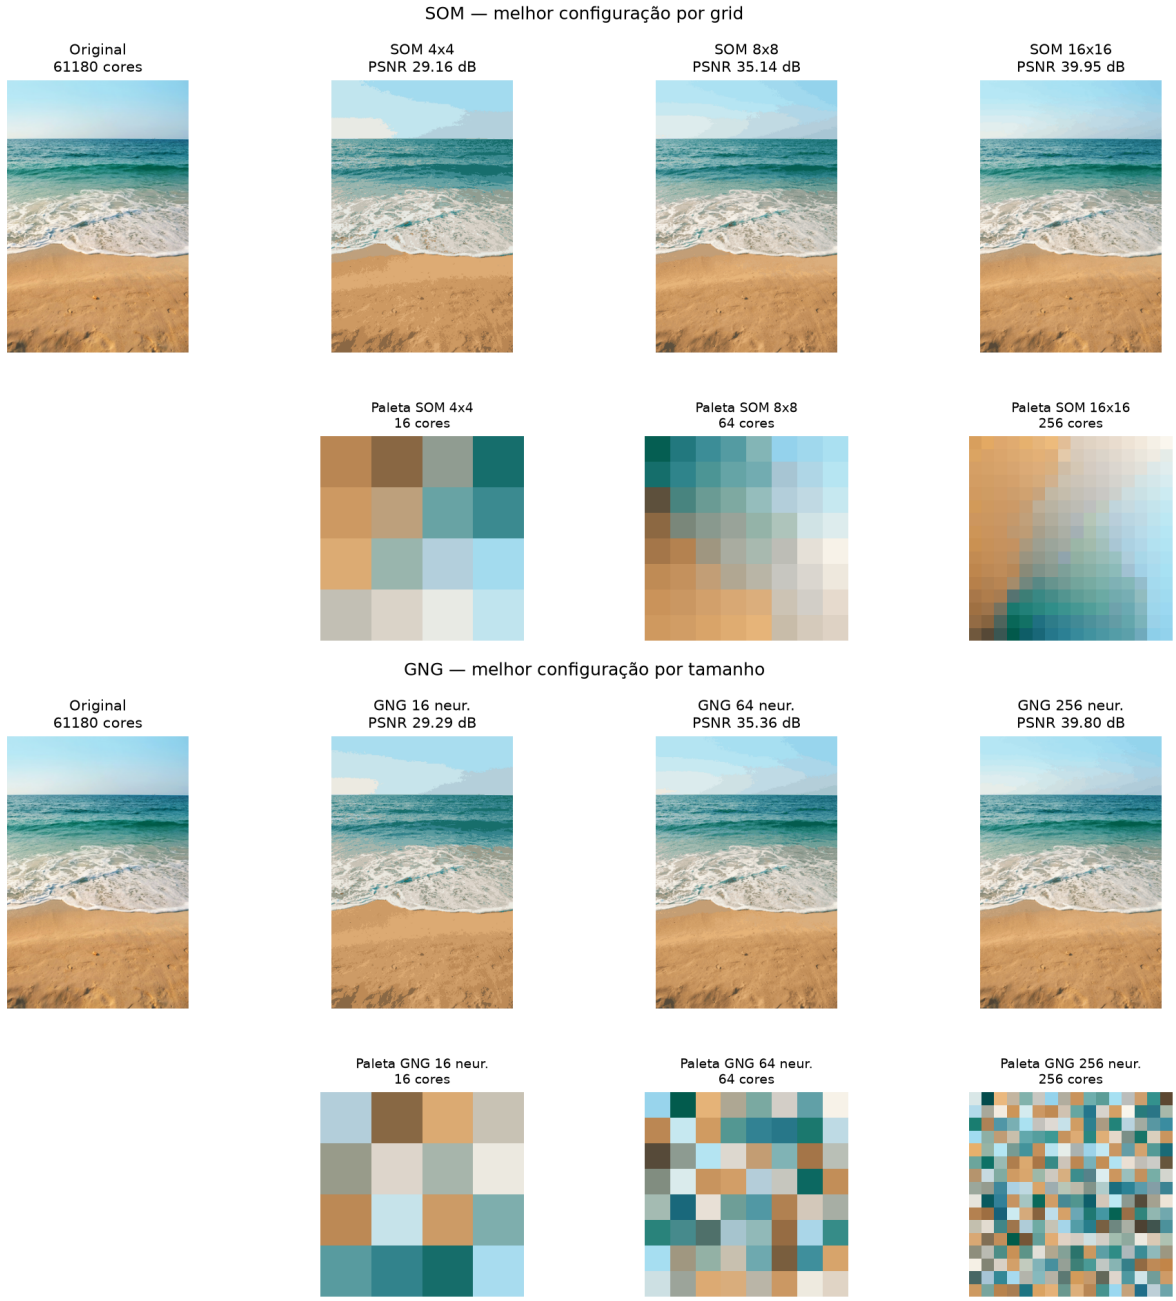


Figura 7: Reconstruções da imagem `praia`.

Tintas

Modelo	Rede	Config.	Cores	EQ	ET	MSE	PSNR (dB)	Tempo (s)
SOM	4x4	A	16	0.1244	0.0559	6.61e-03	21.80	4.4
SOM	4x4	B	16	0.1075	0.1017	5.19e-03	22.84	4.4
SOM	4x4	C	16	0.1276	0.0852	6.77e-03	21.69	4.3
SOM	8x8	A	64	0.0622	0.0332	1.82e-03	27.40	17.1
SOM	8x8	B	64	0.0534	0.0901	1.28e-03	28.93	21.5
SOM	8x8	C	64	0.0643	0.0841	1.90e-03	27.21	19.9
SOM	16x16	A	246	0.0331	0.0485	5.35e-04	32.70	58.3
SOM	16x16	B	245	0.0295	0.1264	4.11e-04	33.84	58.5
SOM	16x16	C	248	0.0324	0.0733	5.05e-04	32.96	57.2
GNG	16 neur.	A	16	0.1113	0.0050	5.46e-03	22.63	12.7
GNG	16 neur.	B	16	0.1064	0.0047	4.92e-03	23.08	12.6
GNG	16 neur.	C	16	0.1116	0.0051	5.41e-03	22.67	13.5
GNG	64 neur.	A	64	0.0561	0.0081	1.39e-03	28.58	15.6
GNG	64 neur.	B	64	0.0539	0.0040	1.27e-03	28.96	14.3
GNG	64 neur.	C	64	0.0554	0.0102	1.37e-03	28.63	14.8
GNG	256 neur.	A	256	0.0301	0.0125	4.16e-04	33.80	18.5
GNG	256 neur.	B	256	0.0296	0.0090	3.90e-04	34.08	17.5
GNG	256 neur.	C	256	0.0302	0.0047	4.23e-04	33.73	16.7

Tabela 8: Imagem `tintas`.

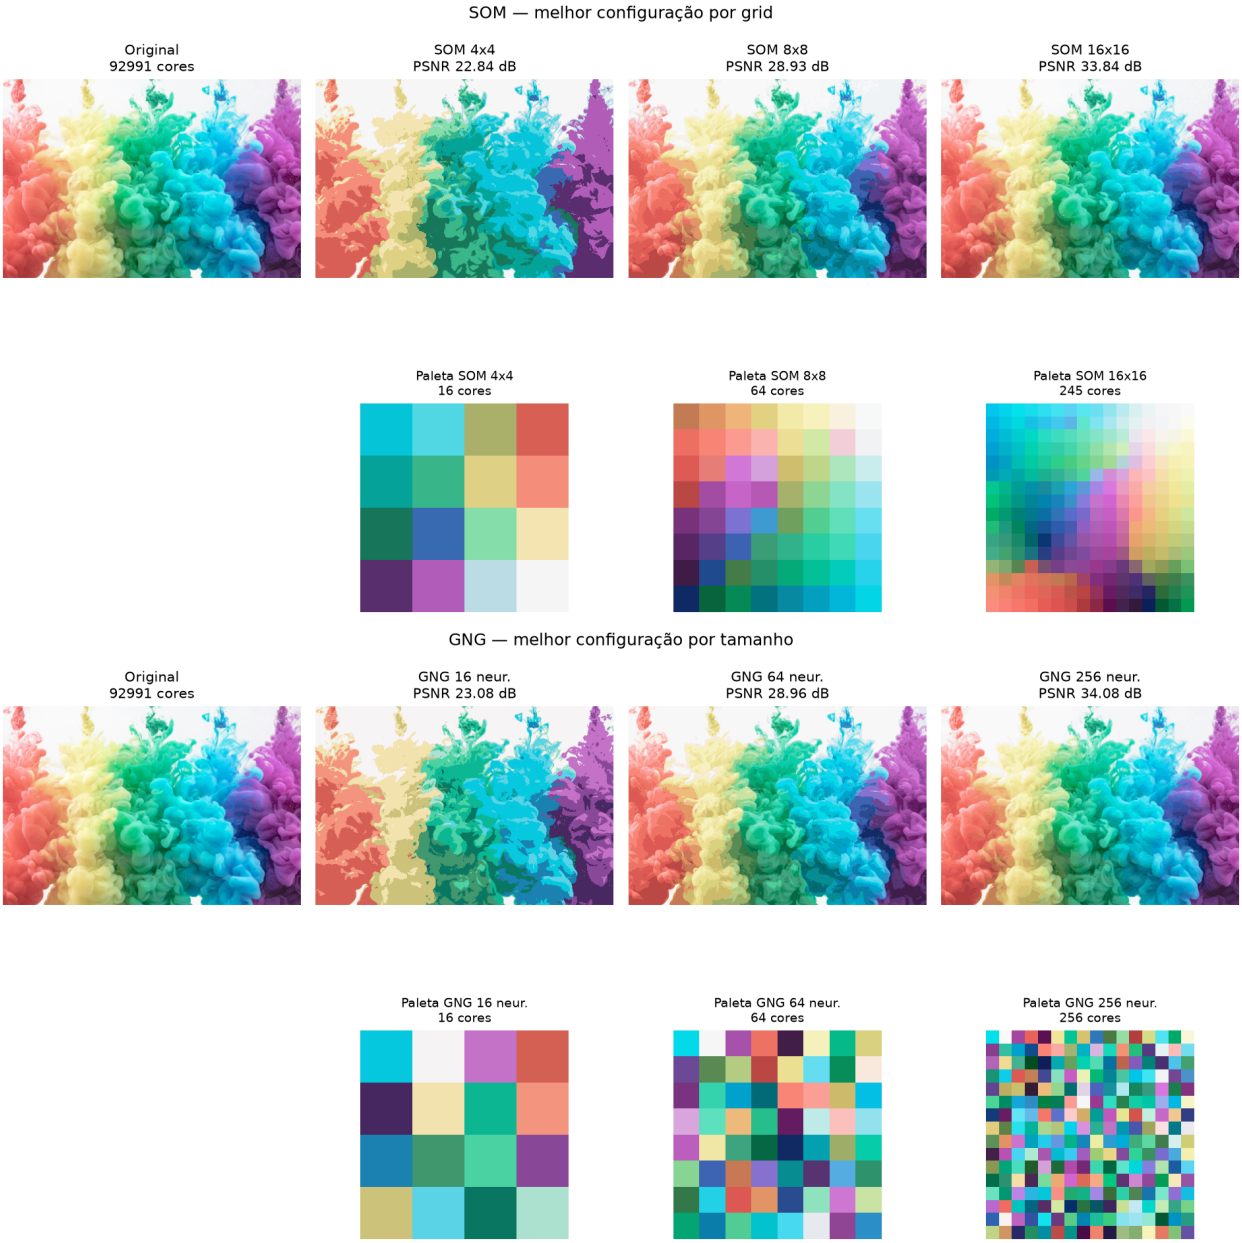


Figura 8: Reconstruções da imagem `tintas`.

Arara

Modelo	Rede	Config.	Cores	EQ	ET	MSE	PSNR (dB)	Tempo (s)
SOM	4x4	A	16	0.0859	0.0000	3.07e-03	25.12	3.7
SOM	4x4	B	16	0.0730	0.0234	2.39e-03	26.21	3.5
SOM	4x4	C	16	0.0861	0.0043	3.18e-03	24.97	3.5
SOM	8x8	A	64	0.0404	0.0123	7.72e-04	31.11	7.5
SOM	8x8	B	64	0.0373	0.0198	6.52e-04	31.85	7.6
SOM	8x8	C	64	0.0439	0.1599	9.50e-04	30.22	7.5
SOM	16x16	A	256	0.0233	0.1163	2.87e-04	35.41	25.9
SOM	16x16	B	256	0.0213	0.1770	2.26e-04	36.44	28.8
SOM	16x16	C	256	0.0230	0.0999	2.85e-04	35.44	25.7
GNG	16 neur.	A	16	0.0806	0.0044	2.84e-03	25.47	10.9
GNG	16 neur.	B	16	0.0751	0.0119	2.49e-03	26.04	11.0
GNG	16 neur.	C	16	0.0829	0.0001	2.93e-03	25.33	11.0
GNG	64 neur.	A	64	0.0393	0.0050	7.27e-04	31.37	12.1
GNG	64 neur.	B	64	0.0376	0.0044	6.66e-04	31.77	12.5
GNG	64 neur.	C	64	0.0391	0.0033	7.37e-04	31.31	12.0
GNG	256 neur.	A	256	0.0221	0.0140	2.44e-04	36.10	15.0
GNG	256 neur.	B	256	0.0222	0.0107	2.29e-04	36.38	15.8
GNG	256 neur.	C	256	0.0221	0.0046	2.46e-04	36.08	14.8

Tabela 9: Imagem `arara`.

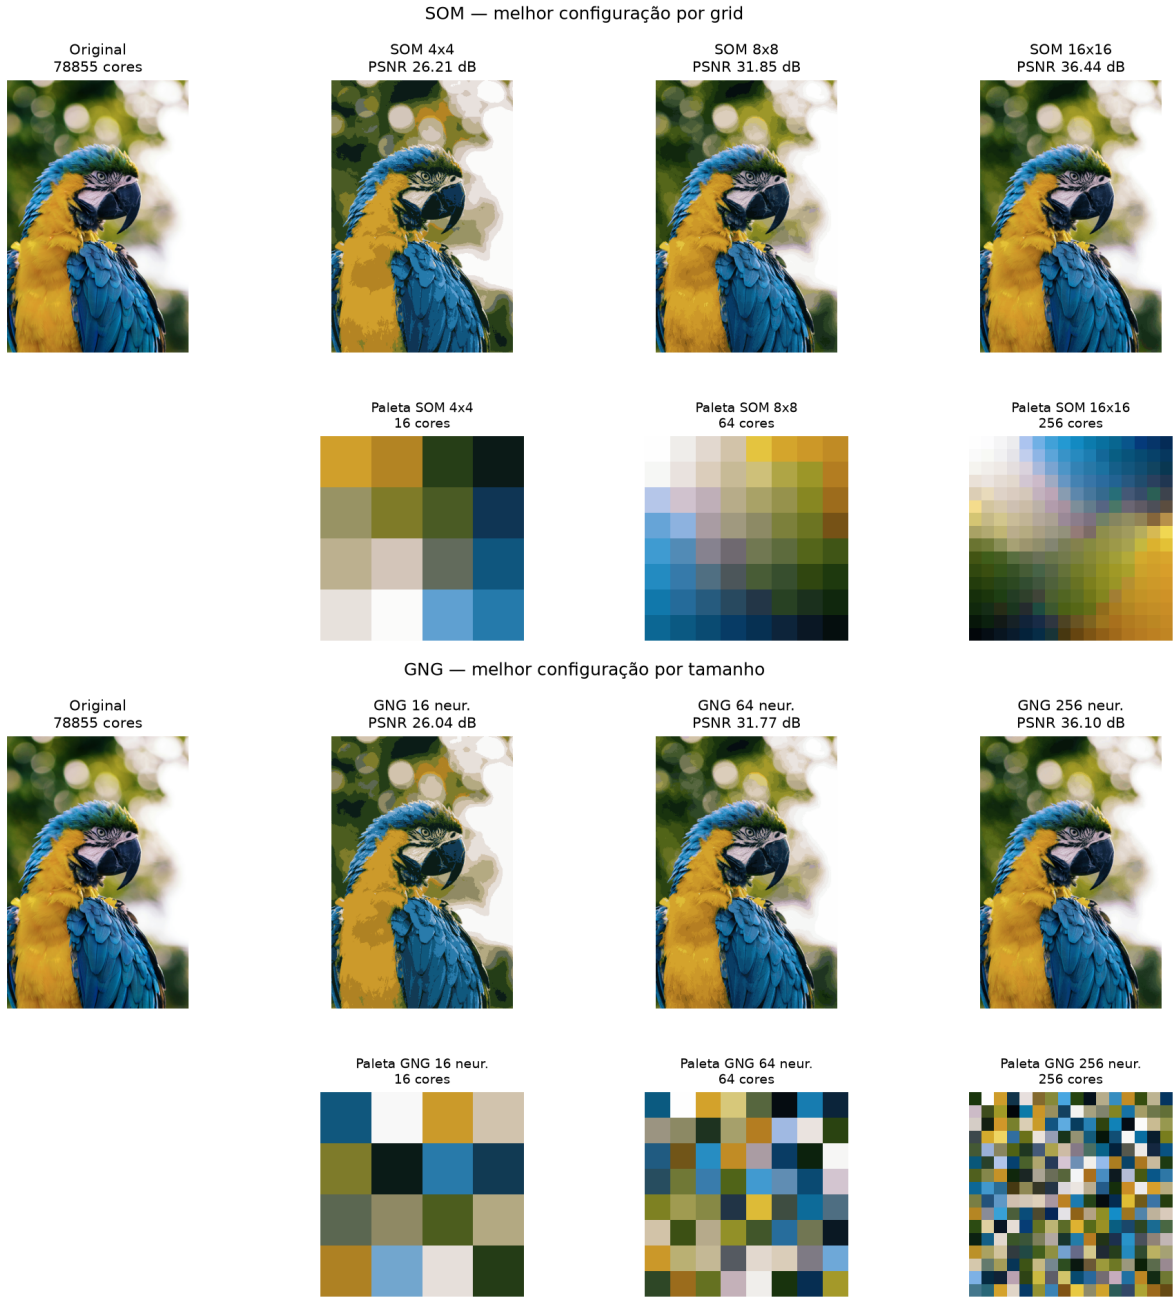


Figura 9: Reconstruções da imagem `arara`.