Projeto 2: Quantização de Cores com Redes SOM e GNG

Disciplina: Introdução às Redes Neurais Artificiais

Autora: Aline Breda Kuster (RA: 168.495)

Repositório: `https://github.com/aline-kuster/Proj2`

Configuração Experimental

O objetivo é reduzir a paleta de cores de uma imagem (compressão) usando dois modelos de aprendizado competitivo não supervisionado: o *Self-Organizing Map* (SOM) e o *Growing Neural Gas* (GNG). Cada pixel é tratado como um vetor $\mathbf{x} = (R, G, B) \in [0,1]^3$; ao final do treino, os pesos dos neurônios formam a paleta, e a imagem é reconstruída trocando cada pixel pela cor do neurônio vencedor (BMU):

$$c(\mathbf{x}) = \arg\min_i \|\mathbf{x} - \mathbf{w}_i\|_2. \tag{1}$$

Foram usadas cinco imagens (diretório `data/input/`), redimensionadas com filtro Lanczos para no máximo 450 pixels de lado ($\approx 135\,000$ pixels cada), com semente aleatória fixa em 42:

Imagem	Conteúdo	Cores distintas
`por_do_sol`	degradê laranja e silhuetas escuras	36 390
`campo`	céu azul, nuvens brancas e grama	38 124
`praia`	céu, mar verde-azulado e areia	61 180
`tintas`	tintas de todas as cores (arco-íris)	92 991
`arara`	arara azul e amarela, fundo desfocado	78 855

Tabela 1: Imagens utilizadas.

Foram avaliadas redes com 16, 64 e 256 neurônios (no SOM, grades 4×4, 8×8 e 16×16), com quatro métricas:

1. **Erro de Quantização (EQ):** distância média entre cada pixel e a cor do seu BMU;
2. **Erro Topológico (ET):** fração de pixels cujo 1º e 2º BMU *não* são vizinhos na rede (no SOM, adjacentes na grade; no GNG, ligados por aresta);
3. **PSNR (dB):** qualidade visual da imagem reconstruída, $10 \log_{10}(255^2/\mathrm{MSE})$;
4. **Cores usadas:** quantos neurônios viraram a cor de algum pixel.

Ajuste de hiperparâmetros. Para cada tamanho de rede foram testadas três configurações (Tabela 2); nas tabelas e figuras a seguir é usada a de menor EQ.

Config.	SOM	GNG
A	$\sigma_0 = L/2$, $\sigma_N = 1{,}0$	$\varepsilon_b = 0{,}2$, $\varepsilon_n = 0{,}006$, $\lambda = 100$, $a_{\max} = 50$
B	$\sigma_0 = L/2$, $\sigma_N = 0{,}5$	$\varepsilon_b = 0{,}05$, $\varepsilon_n = 0{,}0006$, $\lambda = 100$, $a_{\max} = 50$
C	$\sigma_0 = L/4$, $\sigma_N = 1{,}0$	$\varepsilon_b = 0{,}2$, $\varepsilon_n = 0{,}006$, $\lambda = 300$, $a_{\max} = 100$

Tabela 2: Configurações testadas (L = lado da grade).

1. Mapas Auto-Organizáveis (SOM)

O SOM foi treinado com a biblioteca *XPySom* por 100 épocas (todos os pixels a cada época), com pesos iniciais sorteados entre os pixels e vizinhança gaussiana cujo raio σ decai exponencialmente de σ_0 até σ_N. A XPySom usa o *batch SOM*, em que cada peso é substituído pela média dos pixels ponderada pela vizinhança; nessa conta a taxa de aprendizado se cancela, por isso o ajuste foi feito no raio σ. O projeto também traz uma implementação própria do SOM online (`-som-impl propria`).

Imagem	Grade	Config.	EQ	ET	PSNR (dB)	Cores
`por_do_sol`	4x4	B	0,0307	0,0000	33,39	16
`por_do_sol`	8x8	B	0,0158	0,1510	39,01	64
`por_do_sol`	16x16	B	0,0086	0,2063	44,23	255
`campo`	4x4	B	0,0421	0,0068	30,58	15
`campo`	8x8	B	0,0183	0,0553	37,28	62
`campo`	16x16	B	0,0098	0,1652	43,12	254
`praia`	4x4	B	0,0521	0,0466	29,16	16
`praia`	8x8	B	0,0257	0,0661	35,14	64
`praia`	16x16	B	0,0145	0,0697	39,95	256
`tintas`	4x4	B	0,1075	0,1017	22,84	16
`tintas`	8x8	B	0,0534	0,0901	28,93	64
`tintas`	16x16	B	0,0295	0,1264	33,84	245
`arara`	4x4	B	0,0730	0,0234	26,21	16
`arara`	8x8	B	0,0373	0,0198	31,85	64
`arara`	16x16	B	0,0213	0,1770	36,44	256
Média	4x4	–	0,0611	0,0357	28,44	15,8
Média	8x8	–	0,0301	0,0765	34,44	63,6
Média	16x16	–	0,0167	0,1489	39,51	253,2

Tabela 3: Métricas do SOM (melhor configuração de cada grade).

Dobrar o lado da grade reduz o erro de quantização aproximadamente pela metade, e o PSNR médio sobe de 28,4 dB (16 cores) para 34,4 dB (64) e 39,5 dB (256). Com 16 cores aparecem faixas (posterização) nos degradês; com 256 a reconstrução é praticamente igual à original. Já o erro topológico *aumenta* com a grade (média de 0,036 para 0,149): quanto mais neurônios, mais a grade 2D precisa se dobrar para cobrir a nuvem de cores 3D. Em compensação, a paleta do SOM sai organizada, com cores parecidas lado a lado (Figura 2).

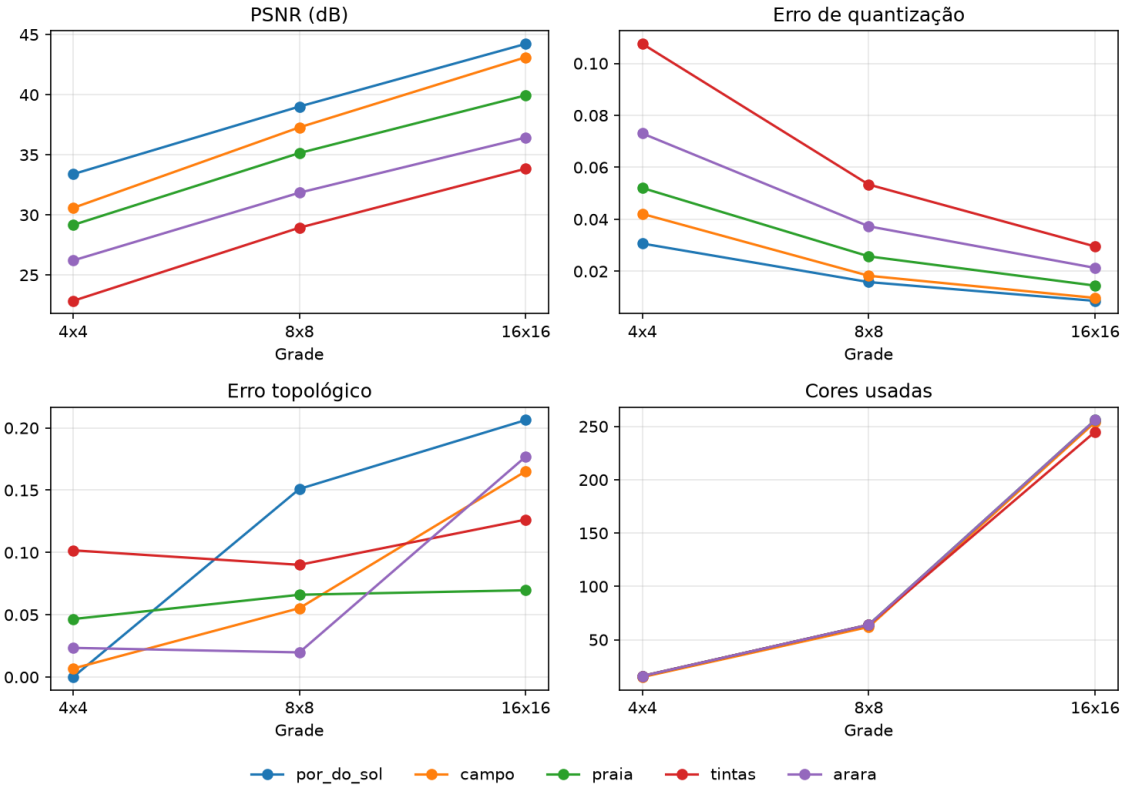


Figura 1: Desempenho do SOM em função do tamanho da grade, nas cinco imagens.

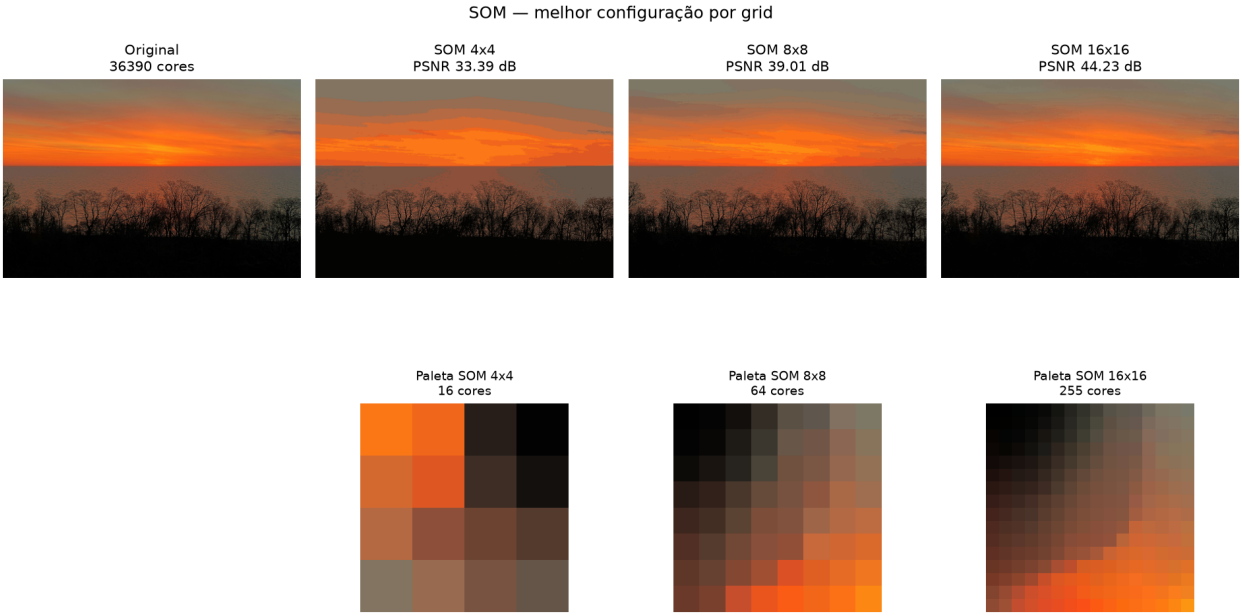


Figura 2: SOM no `por_do_sol`: reconstruções e paletas (na posição da grade).

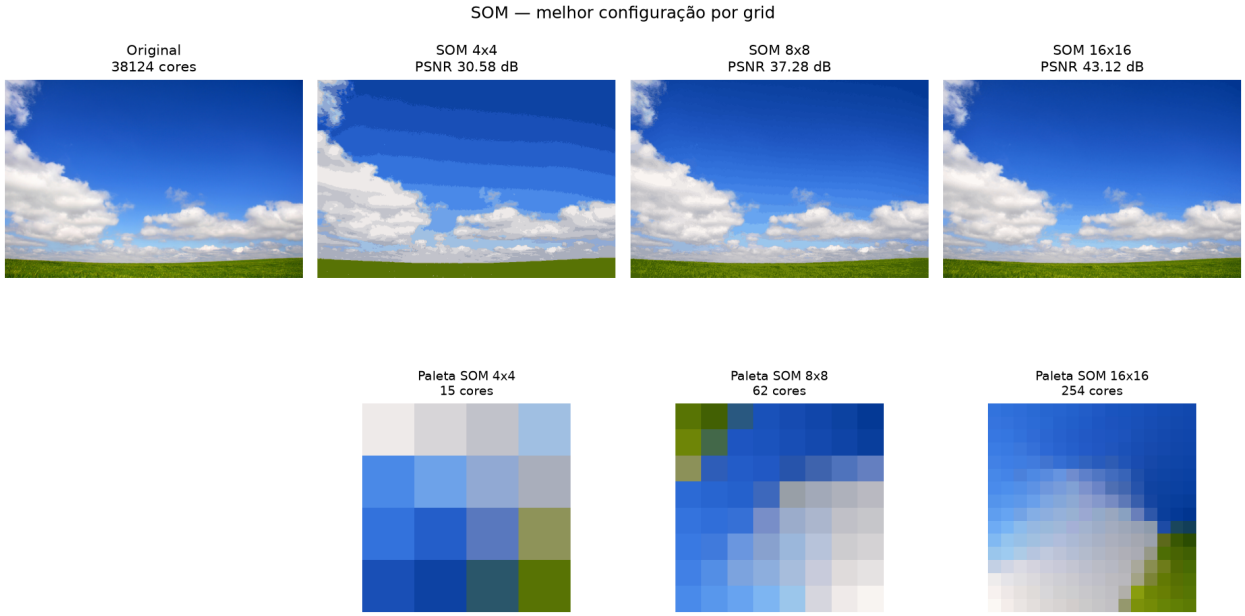


Figura 3: SOM no `campo`.

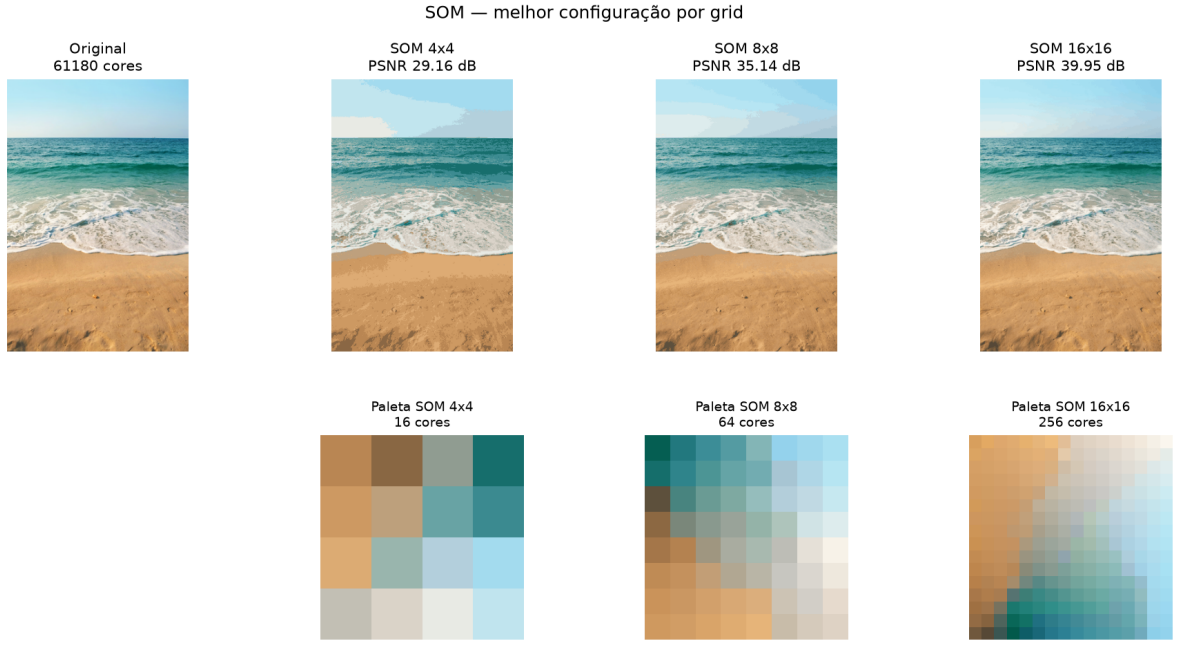


Figura 4: SOM na `praia`.

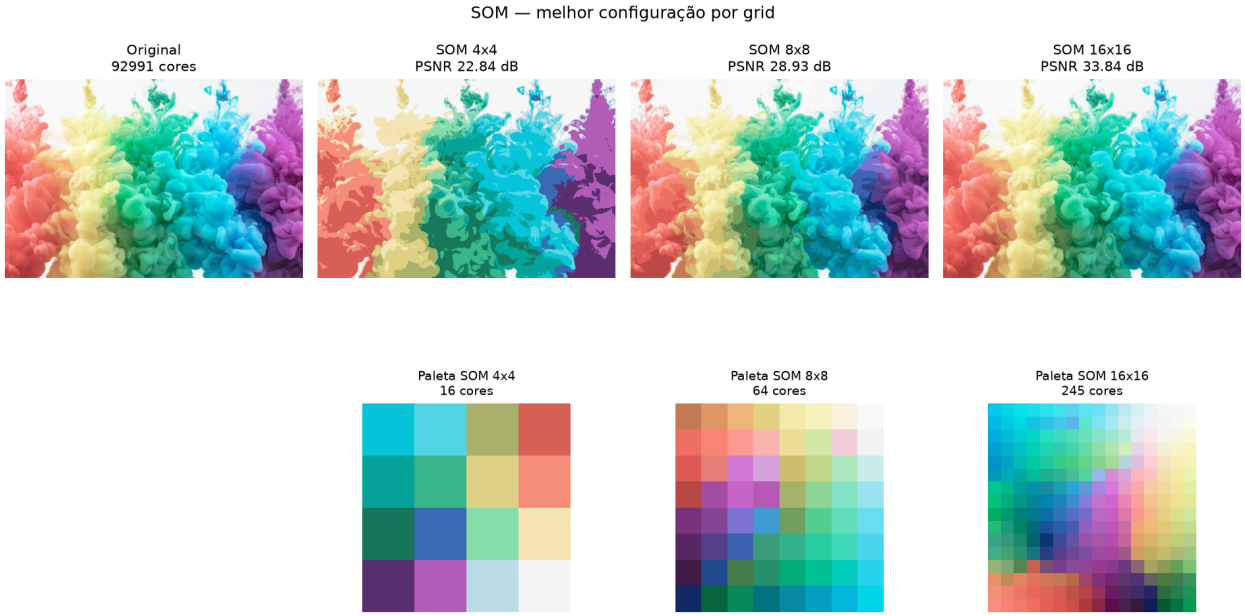


Figura 5: SOM nas `tintas`, a imagem mais difícil (cores espalhadas por todo o cubo RGB).

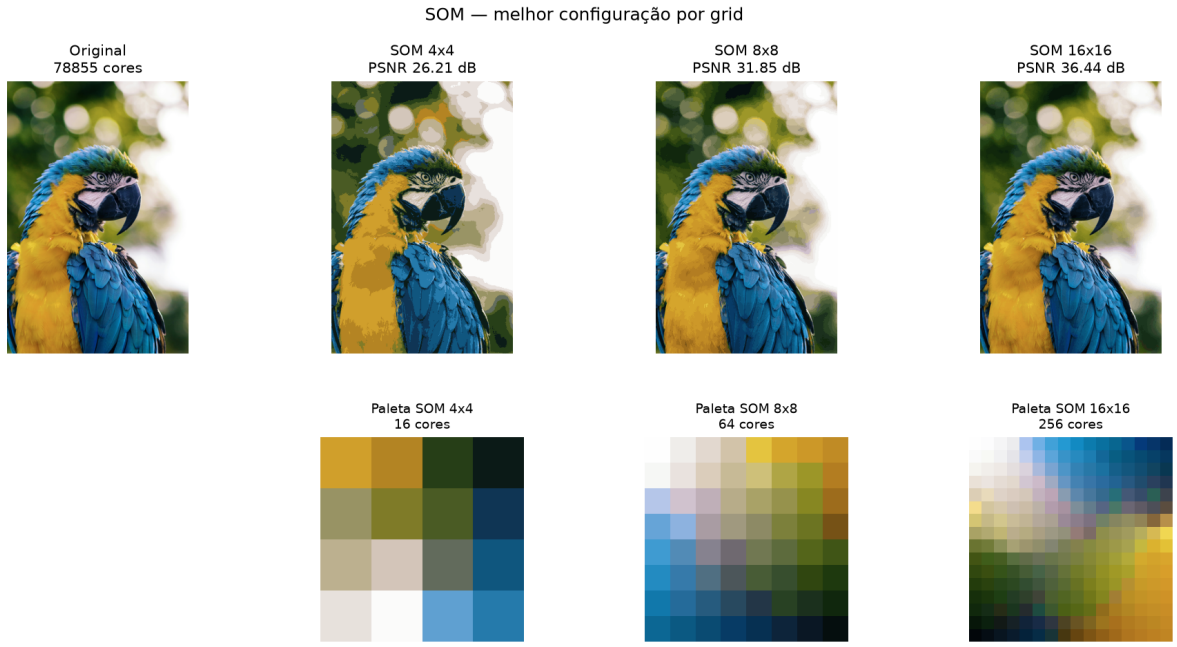


Figura 6: SOM na `arara`.

2. Growing Neural Gas (GNG)

O GNG foi implementado do zero (Fritzke, 1995). A rede começa com 2 neurônios; a cada pixel, o vencedor s_1 e seus vizinhos são movidos em direção à amostra (taxas ε_b e ε_n), a aresta s_1–s_2 é criada ou renovada, e arestas com idade maior que $a_{\max}$ são removidas. A cada λ iterações é inserido um neurônio entre o de maior erro acumulado e seu vizinho de maior erro ($\alpha = 0{,}5$, $d = 0{,}995$). O treino dura 2 épocas ($\approx 270\,000$ iterações): primeiro a rede cresce até o tamanho final e depois faz o ajuste fino.

Imagem	Neurônios	Config.	EQ	ET	PSNR (dB)	Cores
`por_do_sol`	16	B	0,0308	0,0011	33,31	16
`por_do_sol`	64	B	0,0156	0,0016	39,29	64
`por_do_sol`	256	C	0,0085	0,0041	44,12	256
`campo`	16	B	0,0395	0,0028	31,17	16
`campo`	64	A	0,0178	0,0030	37,86	64
`campo`	256	A	0,0101	0,0089	43,01	256
`praia`	16	B	0,0517	0,0036	29,29	16
`praia`	64	B	0,0257	0,0080	35,36	64
`praia`	256	A	0,0152	0,0090	39,80	256
`tintas`	16	B	0,1064	0,0047	23,08	16
`tintas`	64	B	0,0539	0,0040	28,96	64
`tintas`	256	B	0,0296	0,0090	34,08	256
`arara`	16	B	0,0751	0,0119	26,04	16
`arara`	64	B	0,0376	0,0044	31,77	64
`arara`	256	A	0,0221	0,0140	36,10	256
Média	16	–	0,0607	0,0048	28,58	16,0
Média	64	–	0,0301	0,0042	34,65	64,0
Média	256	–	0,0171	0,0090	39,42	256,0

Tabela 4: Métricas do GNG (melhor configuração de cada tamanho).

O PSNR médio do GNG foi de 28,6 dB (16 neurônios), 34,7 dB (64) e 39,4 dB (256), muito próximo do SOM. A grande diferença está no erro topológico, que ficou sempre abaixo de 0,015 (média de 0,004 a 0,009). Como as arestas ligam exatamente o 1º e o 2º BMU de cada pixel, a topologia do grafo acompanha a distribuição real das cores (Figura 13). A paleta, por outro lado, não tem ordem visual, pois os neurônios ficam na ordem em que foram inseridos.

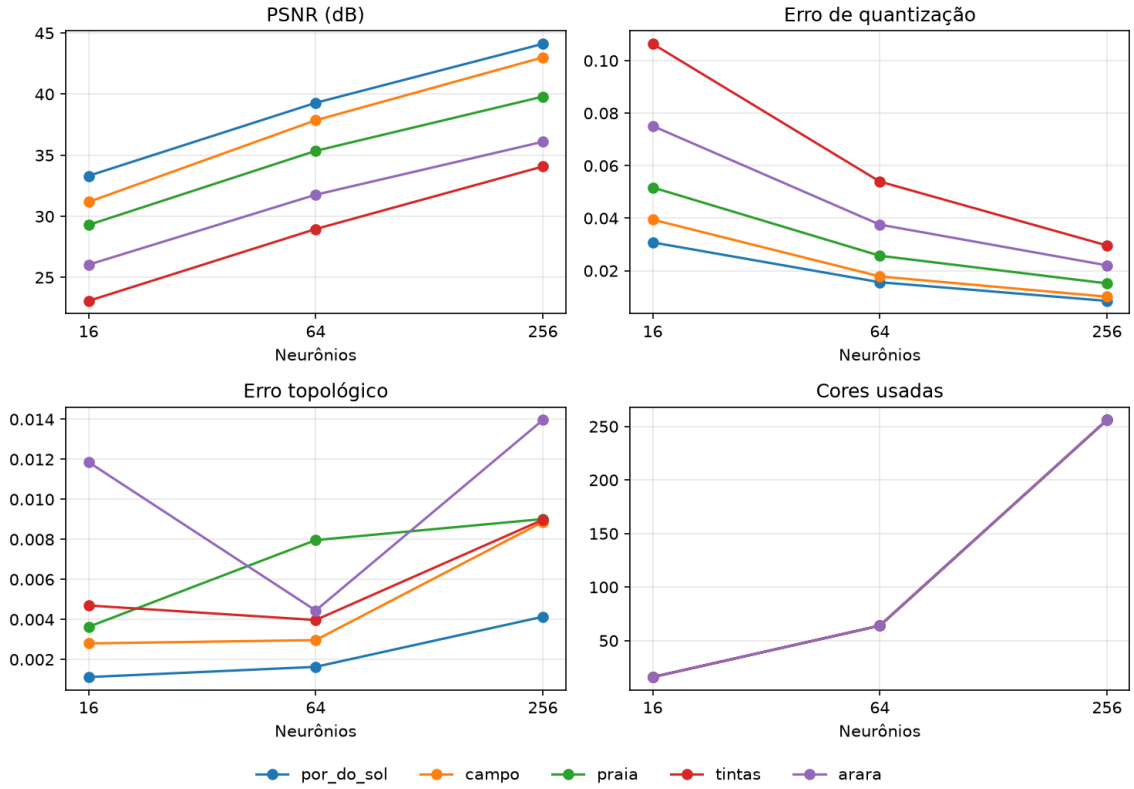


Figura 7: Desempenho do GNG em função do número de neurônios. Atenção à escala do erro topológico: cerca de 15 vezes menor que a do SOM.

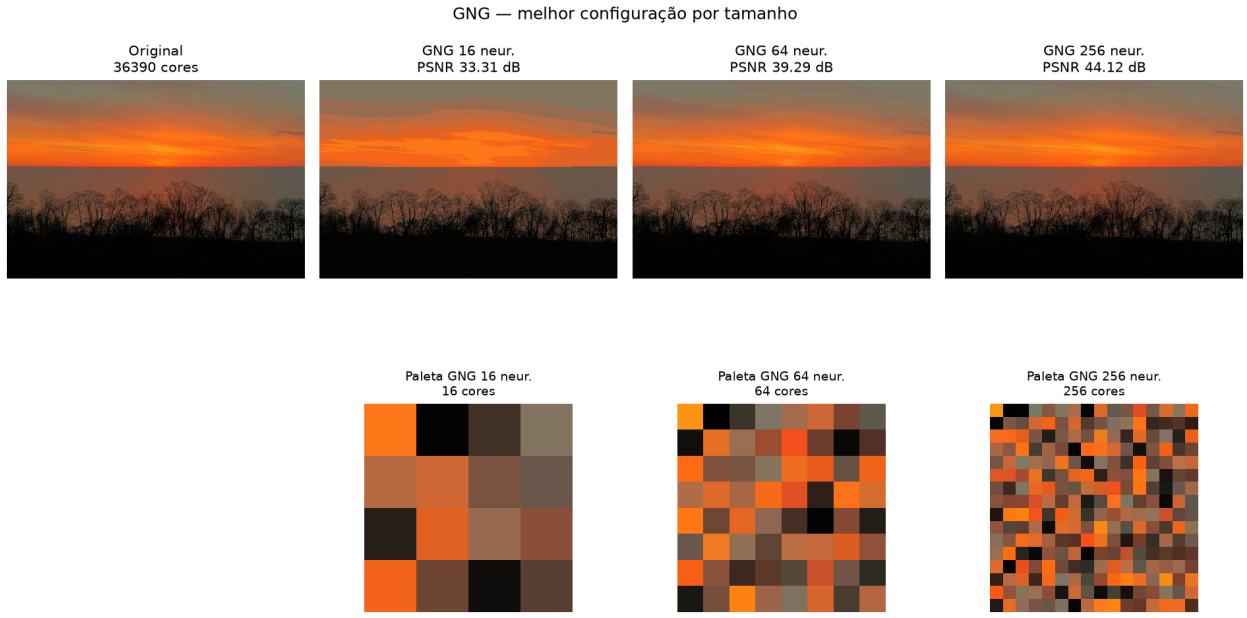


Figura 8: GNG no `por_do_sol`: reconstruções e paletas (na ordem de inserção).

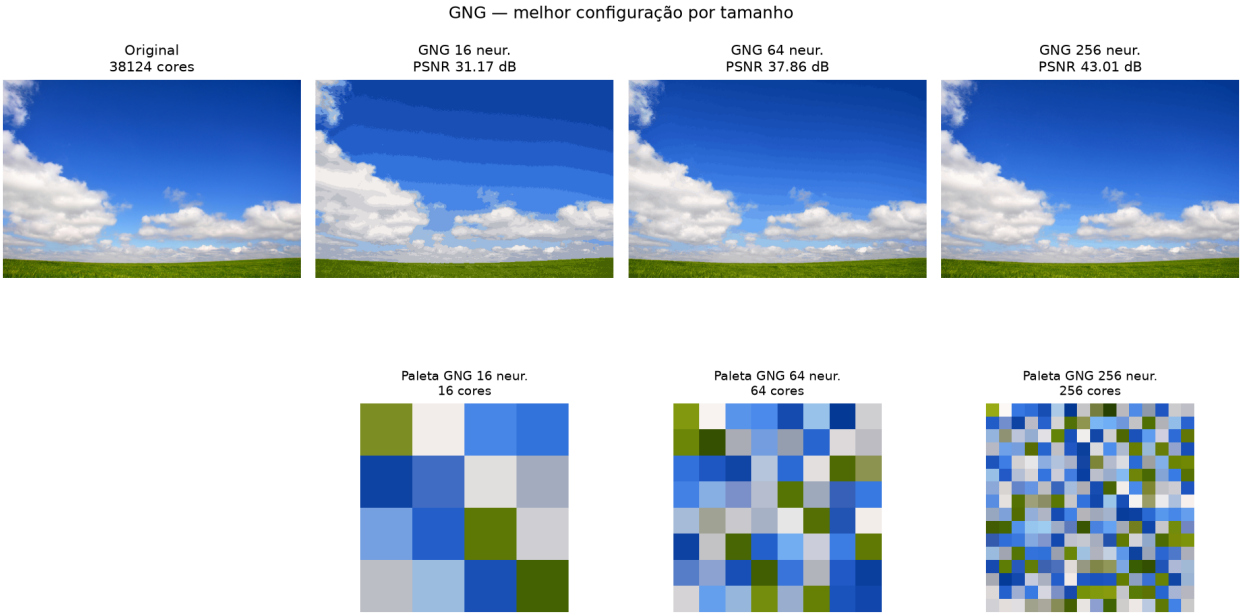


Figura 9: GNG no `campo`.

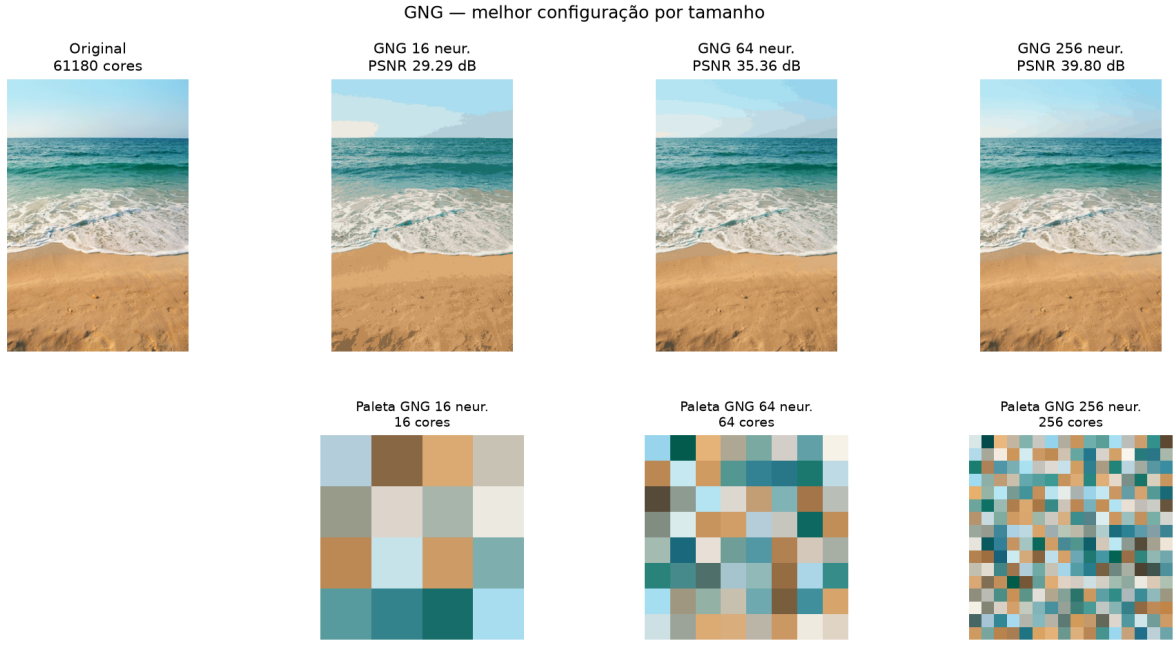


Figura 10: GNG na `praia`.

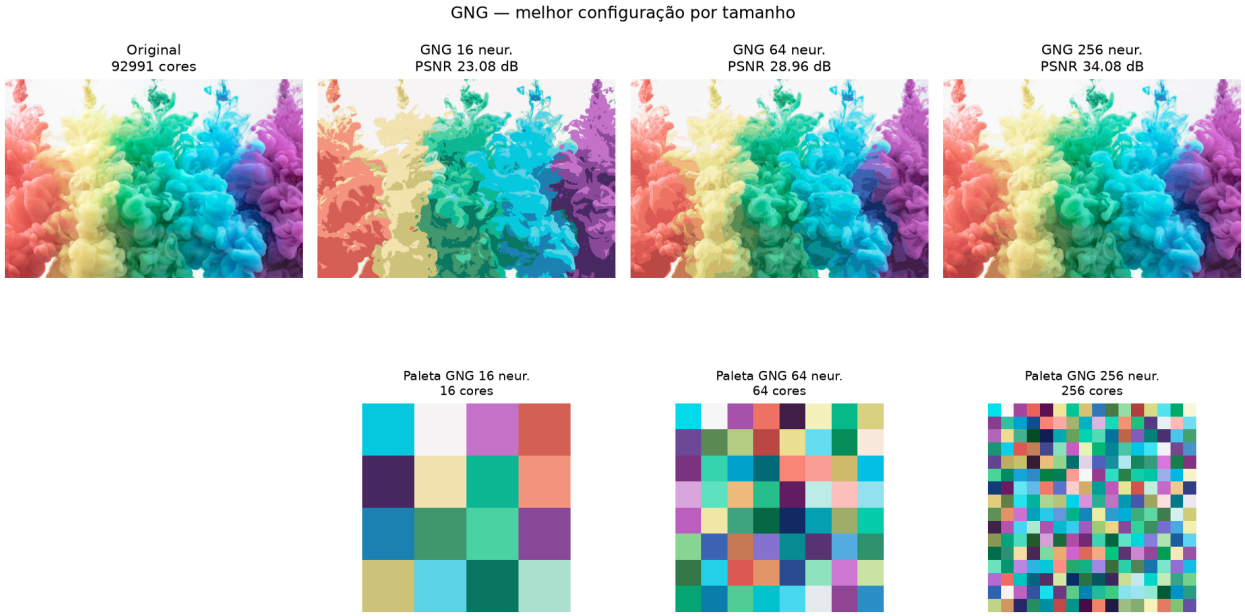


Figura 11: GNG nas `tintas`.

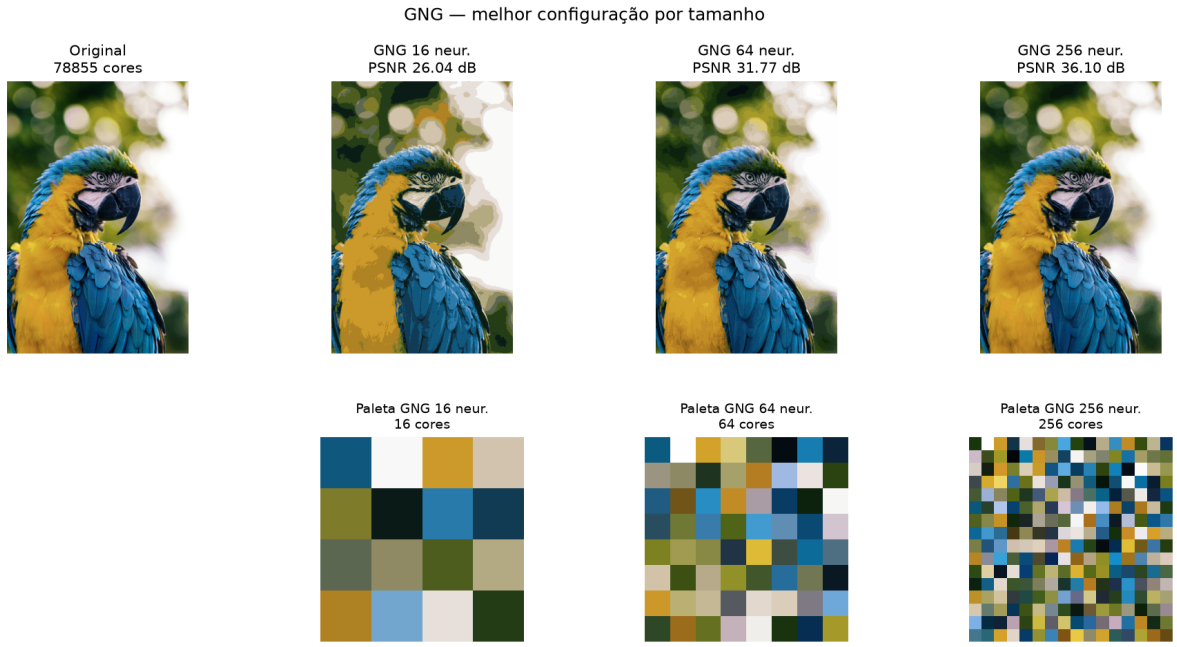
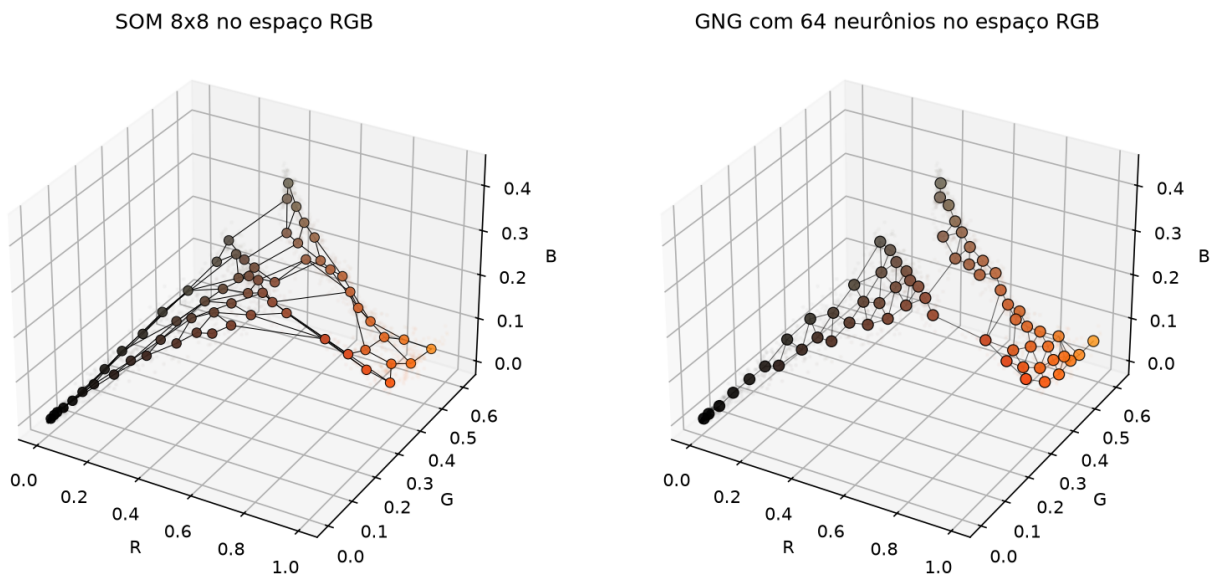


Figura 12: GNG na `arara`.



(a) SOM 8×8: a grade se dobra para cobrir as cores. (b) GNG com 64 neurônios: o grafo segue as cores.

Figura 13: Topologia das redes no espaço RGB (`por_do_sol`).

3. Ajuste de Hiperparâmetros

Modelo	Config.	EQ médio	ET médio	Menor EQ	Menor ET
SOM	A	0,0413	0,0526	0/15	10/15
SOM	B	0,0360	0,0870	15/15	2/15
SOM	C	0,0425	0,1045	0/15	3/15
GNG	A	0,0373	0,0069	4/15	1/15
GNG	B	0,0362	0,0052	10/15	5/15
GNG	C	0,0375	0,0038	1/15	9/15

Tabela 5: Efeito das configurações: médias nas 15 combinações (5 imagens $\times$ 3 tamanhos) e em quantas delas cada configuração teve o menor erro.

No SOM, a configuração B (vizinhança final menor) teve o menor EQ em todos os 15 casos, mas o maior ET médio: sem a vizinhança puxando os neurônios, o SOM se comporta como um k-means e o mapa se desorganiza. A A (vizinhança final maior) preserva melhor a topologia, e a C (vizinhança inicial menor) foi a pior nos dois erros, porque a grade não consegue se desdobrar no início do treino. No GNG, taxas menores (B) deram o menor EQ na maioria dos casos, e inserir neurônios com menos frequência (C, λ maior) deu o menor ET, pois cada neurônio novo tem mais tempo para se encaixar antes do próximo.

4. Análise Comparativa

	16 protótipos		64 protótipos		256 protótipos	
Imagem	SOM	GNG	SOM	GNG	SOM	GNG
PSNR (dB) – quanto maior, melhor						
`por_do_sol`	33,39	33,31	39,01	39,29	44,23	44,12
`campo`	30,58	31,17	37,28	37,86	43,12	43,01
`praia`	29,16	29,29	35,14	35,36	39,95	39,80
`tintas`	22,84	23,08	28,93	28,96	33,84	34,08
`arara`	26,21	26,04	31,85	31,77	36,44	36,10
Média	**28,44**	**28,58**	**34,44**	**34,65**	**39,51**	**39,42**
Erro topológico – quanto menor, melhor						
`por_do_sol`	0,0000	0,0011	0,1510	0,0016	0,2063	0,0041
`campo`	0,0068	0,0028	0,0553	0,0030	0,1652	0,0089
`praia`	0,0466	0,0036	0,0661	0,0080	0,0697	0,0090
`tintas`	0,1017	0,0047	0,0901	0,0040	0,1264	0,0090
`arara`	0,0234	0,0119	0,0198	0,0044	0,1770	0,0140
Média	**0,0357**	**0,0048**	**0,0765**	**0,0042**	**0,1489**	**0,0090**

Tabela 6: Comparação direta SOM × GNG (melhor configuração de cada).

Na qualidade da reconstrução os dois modelos praticamente empatam: a diferença de PSNR nunca passa de 0,6 dB e as médias ficam a menos de 0,25 dB uma da outra. Esse empate, porém, só acontece porque a melhor configuração do SOM foi sempre a B; com $\sigma_N = 1{,}0$ (A ou C) o GNG tem EQ menor em todos os casos. Na preservação topológica a diferença é grande: o ET médio do SOM é de 7 a 18 vezes o do GNG. Ou seja, no SOM é preciso escolher entre fidelidade de cor e organização do mapa, enquanto o GNG consegue as duas coisas.

A dificuldade de cada imagem depende de quão espalhadas estão suas cores no espaço RGB: o `por_do_sol`, cujas cores formam praticamente uma curva do preto ao laranja, chegou a 44 dB com 256 cores; as `tintas`, com cores de todos os matizes, ficaram em 34 dB.

Em resumo, com 256 neurônios ambos os modelos produzem imagens praticamente indistinguíveis da original. Para a compressão em si, o GNG é a melhor escolha, pois atinge a mesma fidelidade preservando a topologia; o SOM é mais útil quando se deseja uma paleta organizada em grade, fácil de visualizar e interpretar.