Projeto 2 – Aprendizado Não Supervisionado

Quantização de Cores com Self-Organizing Maps (SOM) e Growing Neural Gas (GNG)

Aline Breda Kuster (RA: *preencher*)

Disciplina: *preencher*

Repositório: *preencher*

13 de outubro de 2026

1 Objetivo

Reduzir drasticamente a paleta de cores de uma imagem (compressão) usando aprendizado competitivo, comparando o SOM (topologia fixa em uma grade 2D) com o GNG (topologia que cresce e se adapta aos dados), e avaliando as redes pelo erro de quantização e pelo erro topológico.

2 Metodologia

2.1 Extração

Cada imagem é carregada em RGB e redimensionada (filtro Lanczos, mantendo a proporção) para no máximo 450 pixels de lado, para manter o treino viável. Todos os pixels são extraídos e normalizados, de modo que cada pixel vira uma amostra $\mathbf{x} = (R, G, B) \in [0, 1]^3$: a imagem passa a ser um conjunto de dados 3D. Foram usadas três imagens:

Imagem	Dimensão	Pixels (amostras)	Cores distintas
`astronaut`	450×450	202 500	93 663
`coffee`	450×300	135 000	62 853
`chelsea`	450×299	134 550	63 505

Tabela 1: Imagens utilizadas após o redimensionamento.

2.2 Treinamento

SOM. Grades 4×4, 8×8 e 16×16, treinadas com a biblioteca **XPySom** por 100 épocas (em cada época todos os pixels são apresentados à rede). Os pesos iniciais são pixels aleatórios da imagem; a vizinhança é gaussiana, $h_{ij} = \exp\big(-\|\mathbf{r}_i - \mathbf{r}_j\|^2 / 2\sigma(t)^2\big)$, com $\sigma(t)$ decaindo exponencialmente de σ_0 até σ_N.

A XPySom implementa o *batch SOM*: em vez de mover os pesos a cada pixel, ela acumula, ao longo do lote, a média dos pixels ponderada pela vizinhança e substitui os pesos por essa média,

$$\mathbf{w}_j \leftarrow \frac{\sum_k h_{c(\mathbf{x}_k)\,j}\ \mathbf{x}_k}{\sum_k h_{c(\mathbf{x}_k)\,j}}.$$

Como a taxa de aprendizado $\eta(t)$ multiplica o numerador e o denominador, ela se cancela e *não tem efeito* nesse algoritmo. Por isso, no SOM, o ajuste de hiperparâmetros foi feito na largura da vizinhança (σ_0 e σ_N), que é a "taxa" que controla quanto cada neurônio puxa os seus vizinhos. O projeto também inclui uma implementação própria do SOM online (`-som-impl propria`), em que $\eta(t)$ é usada.

GNG. Implementação própria seguindo Fritzke (1995), com redes de 16, 64 e 256 neurônios. A rede começa com 2 neurônios; a cada pixel, o vencedor s_1 e seus vizinhos topológicos são movidos em direção à amostra (taxas ε_b e ε_n), a aresta s_1–s_2 é criada ou tem a idade zerada, e arestas com idade maior que $a_{\max}$ são removidas. A cada λ iterações um neurônio é inserido entre o neurônio de maior erro acumulado e o seu vizinho de maior erro ($\alpha = 0{,}5$, $d = 0{,}995$). O treino dura 2 épocas (por exemplo, 405 000 iterações na `astronaut`): a primeira parte serve para a rede crescer até o tamanho final e o restante para o ajuste fino.

Ajuste de hiperparâmetros. Para cada tamanho de rede foram testadas três configurações. A melhor (menor erro de quantização) é usada nas figuras.

Config.	SOM (XPySom)	GNG
A	$\sigma_0 = L/2$, $\sigma_N = 1{,}0$	$\varepsilon_b = 0{,}2$, $\varepsilon_n = 0{,}006$, $\lambda = 100$, $a_{\max} = 50$
B	$\sigma_0 = L/2$, $\sigma_N = 0{,}5$	$\varepsilon_b = 0{,}05$, $\varepsilon_n = 0{,}0006$, $\lambda = 100$, $a_{\max} = 50$
C	$\sigma_0 = L/4$, $\sigma_N = 1{,}0$	$\varepsilon_b = 0{,}2$, $\varepsilon_n = 0{,}006$, $\lambda = 300$, $a_{\max} = 100$

Tabela 2: Configurações testadas (L = lado da grade do SOM).

2.3 Inferência e reconstrução

Para cada pixel original encontra-se o neurônio vencedor (BMU), $c(\mathbf{x}) = \arg\min_i \|\mathbf{x} - \mathbf{w}_i\|$, e a cor do pixel é substituída pelos pesos $\mathbf{w}_{c(\mathbf{x})}$. Em seguida a matriz da imagem é reconstruída ($H \times W \times 3$), salva em `data/output/` e exibida na tela ao final da execução.

2.4 Métricas

- **Erro de quantização (EQ):** $\frac{1}{N}\sum_k \|\mathbf{x}_k - \mathbf{w}_{c(\mathbf{x}_k)}\|$ (distância média pixel–BMU, em RGB normalizado).
- **Erro topológico (ET):** fração de pixels cujo 1º e 2º BMU *não* são vizinhos – no SOM, adjacentes na grade (vizinhança-8); no GNG, ligados por uma aresta.
- **MSE** e **PSNR** (dB), como métricas extras de qualidade visual: $\mathrm{PSNR} = 10\log_{10}(255^2/\mathrm{MSE}_{8\,\mathrm{bits}})$.
- **Cores usadas:** quantos neurônios realmente viraram a cor de algum pixel.

3 Resultados

Modelo	Rede	Config.	Cores	EQ	ET	MSE	PSNR (dB)	Tempo (s)
SOM	4x4	A	16	0.0710	0.0324	2.54e-03	25.94	15.8
SOM	4x4	B	16	0.0603	0.0980	1.78e-03	27.49	9.5
SOM	4x4	C	16	0.0770	0.0778	2.87e-03	25.43	9.3
SOM	8x8	A	64	0.0331	0.0571	5.98e-04	32.21	30.5
SOM	8x8	B	64	0.0296	0.1303	4.46e-04	33.49	35.0
SOM	8x8	C	64	0.0349	0.1097	6.86e-04	31.63	34.1
SOM	16x16	A	256	0.0183	0.0890	1.96e-04	37.04	108.4
SOM	16x16	B	256	0.0168	0.1427	1.53e-04	38.12	104.8
SOM	16x16	C	256	0.0185	0.1086	1.99e-04	36.99	102.0
GNG	16 neur.	A	16	0.0653	0.0047	2.02e-03	26.94	23.3
GNG	16 neur.	B	16	0.0607	0.0010	1.77e-03	27.50	23.8
GNG	16 neur.	C	16	0.0643	0.0008	2.00e-03	26.99	22.5
GNG	64 neur.	A	64	0.0305	0.0072	4.99e-04	33.01	24.8
GNG	64 neur.	B	64	0.0297	0.0041	4.43e-04	33.52	41.0
GNG	64 neur.	C	64	0.0308	0.0031	5.13e-04	32.88	22.1
GNG	256 neur.	A	256	0.0173	0.0143	1.65e-04	37.79	26.3
GNG	256 neur.	B	251	0.0177	0.0058	1.59e-04	37.94	25.3
GNG	256 neur.	C	256	0.0174	0.0080	1.68e-04	37.70	24.4

Tabela 3: Todas as execuções na imagem `astronaut` (EQ = erro de quantização, ET = erro topológico).

Neurônios	EQ SOM	EQ GNG	ET SOM	ET GNG	PSNR SOM	PSNR GNG
16	0.0603	0.0607	0.0980	0.0010	27.49	27.50
64	0.0296	0.0297	0.1303	0.0041	33.49	33.52
256	0.0168	0.0173	0.1427	0.0143	38.12	37.79

Tabela 4: Comparação direta SOM × GNG na `astronaut`, com o mesmo número de neurônios (melhor configuração de cada).

	16 neurônios		64 neurônios		256 neurônios	
Imagem	SOM	GNG	SOM	GNG	SOM	GNG
`astronaut`	27,49	27,50	33,49	33,52	38,12	37,79
`coffee`	29,71	29,62	35,49	35,71	40,52	40,32
`chelsea`	30,94	30,82	36,07	36,12	40,32	40,45
Média	**29,38**	**29,31**	**35,02**	**35,12**	**39,65**	**39,52**

Tabela 5: PSNR (dB) da melhor configuração de cada rede, nas três imagens.

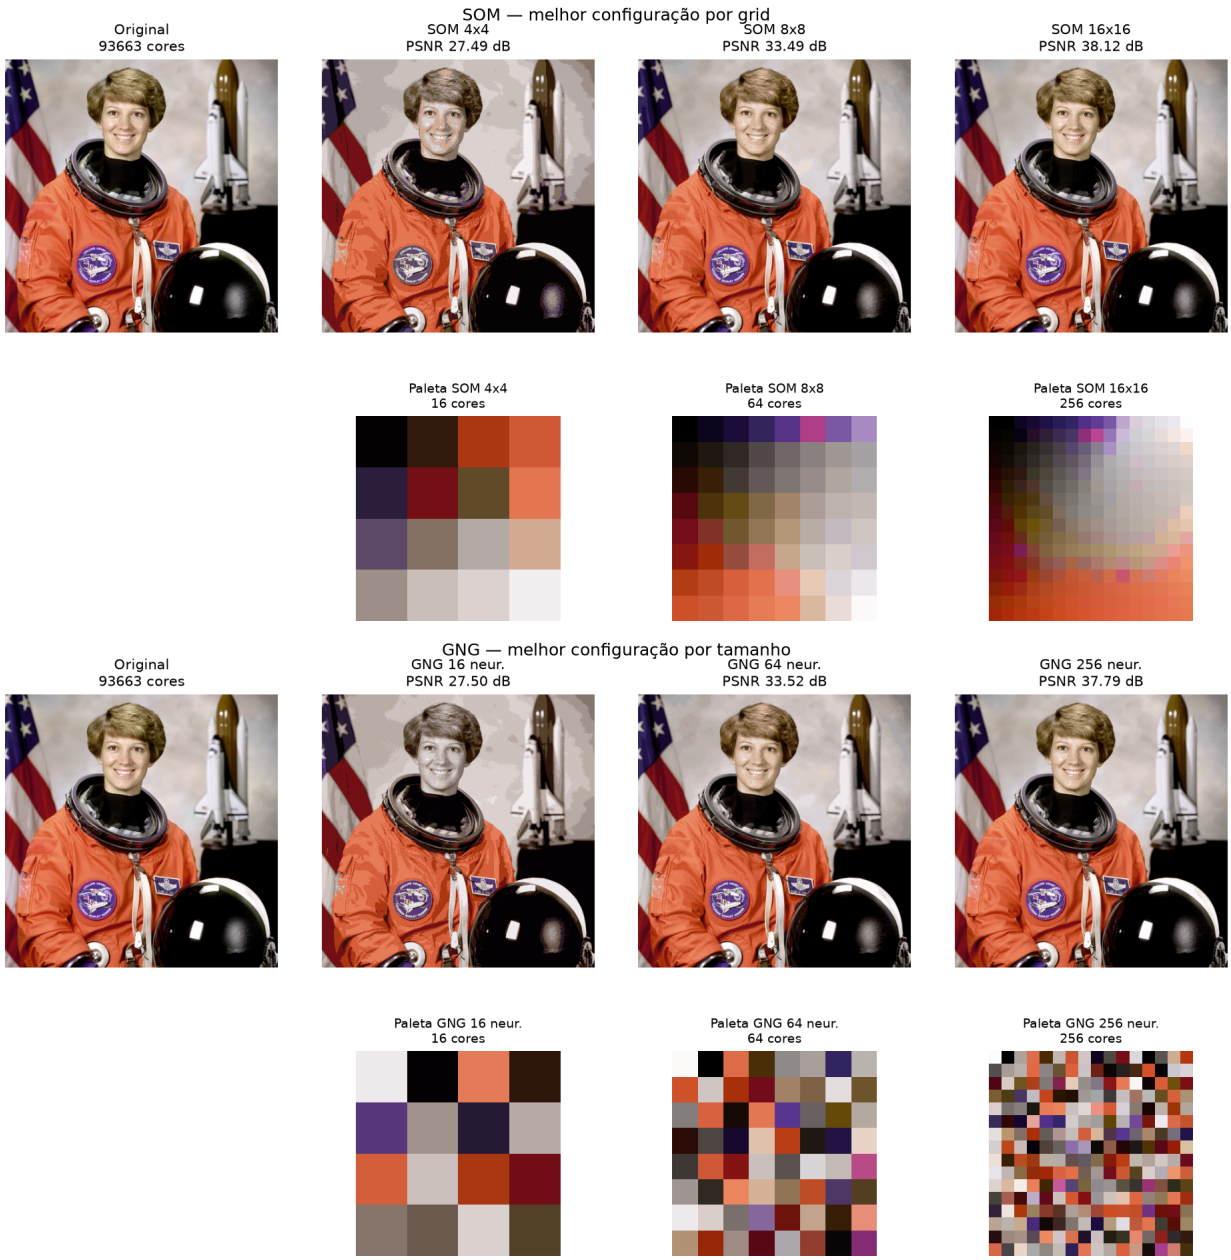


Figura 1: `astronaut`: imagens reconstruídas com a melhor configuração de cada rede e as paletas aprendidas. Na paleta do SOM os pesos estão na posição da grade (cores parecidas ficam vizinhas); na do GNG, na ordem em que os neurônios foram inseridos.

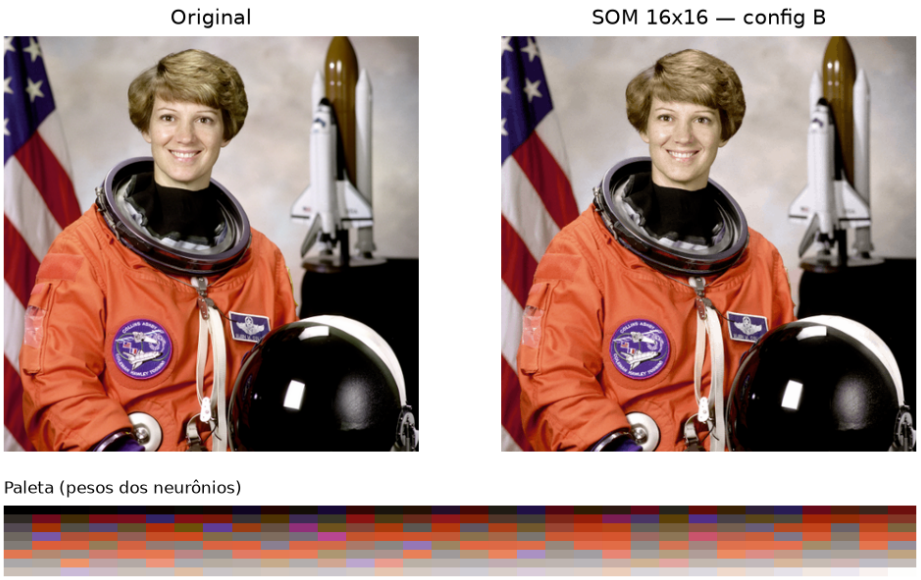


Figura 2: SOM 16×16: original, imagem quantizada e paleta extraída (256 cores).

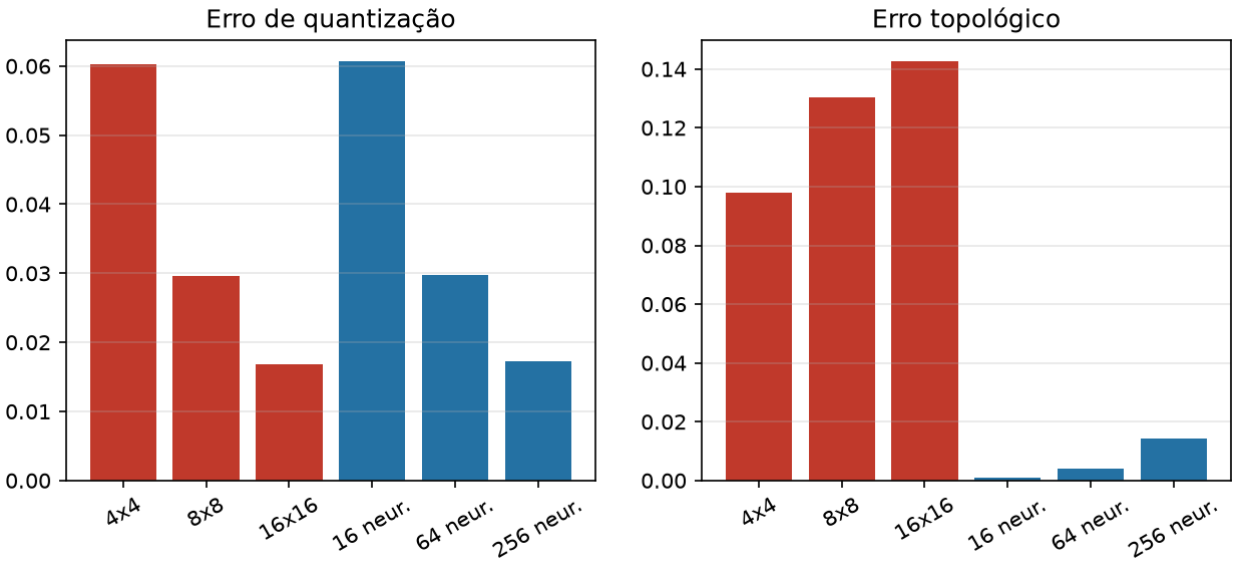
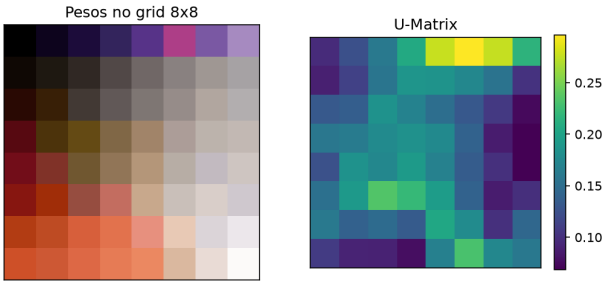
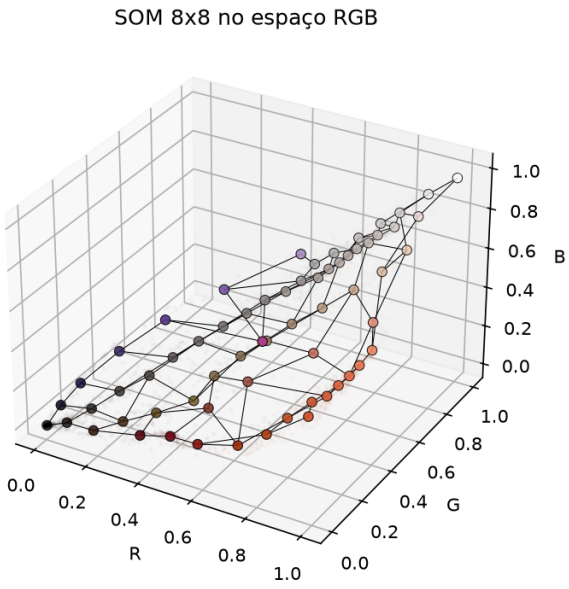


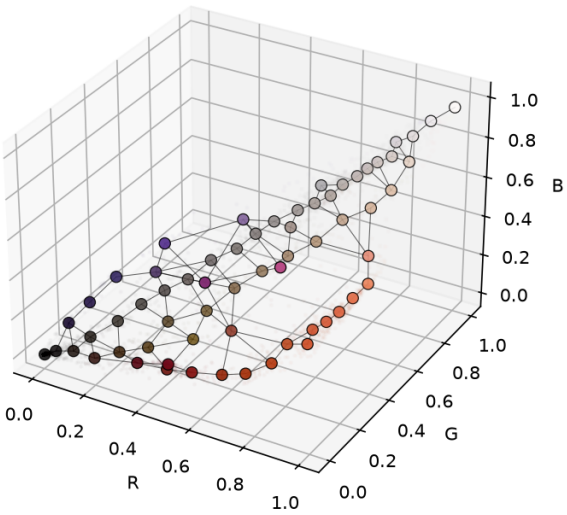
Figura 3: Erros da melhor configuração por rede na `astronaut` (vermelho: SOM; azul: GNG).



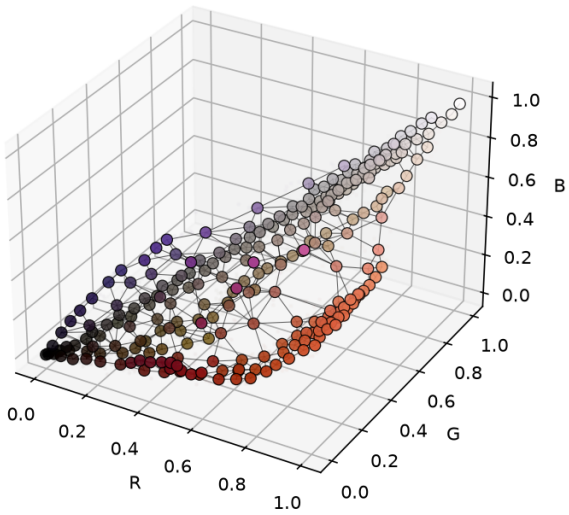
(a) SOM 8×8: pesos na grade e U-Matrix.



(b) SOM 8×8 no espaço RGB.



(c) GNG com 64 neurônios no espaço RGB.



(d) GNG com 256 neurônios no espaço RGB.

Figura 4: Topologia aprendida pelas redes (`astronaut`).

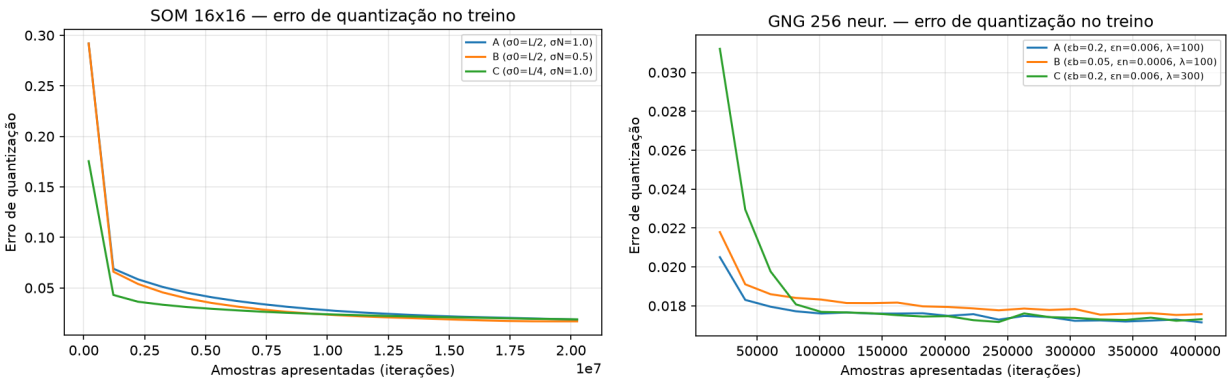


Figura 5: Erro de quantização ao longo do treino para as três configurações (`astronaut`).

4 Discussão

Tamanho da rede. Nos dois modelos, aumentar o número de neurônios reduz o erro de quantização aproximadamente pela metade a cada salto (`astronaut` – SOM: 0,060 → 0,030 → 0,017; GNG: 0,061 → 0,030 → 0,017) e aumenta o PSNR médio em cerca de 5–6 dB (Tabela 5). Com 16 cores aparecem *faixas* (posterização) no fundo e no rosto e o emblema perde o roxo; com 256 cores a imagem fica visualmente muito próxima da original, usando menos de 0,3% das cores distintas.

SOM × GNG: qualidade da reconstrução. Comparando a melhor configuração de cada modelo, os dois praticamente empatam: a diferença de PSNR nunca passa de 0,4 dB e as médias ficam dentro de 0,15 dB (Tabela 5), uma diferença imperceptível a olho nu. Esse empate, porém, só acontece porque a melhor configuração do SOM foi sempre a B, com vizinhança final pequena ($\sigma_N = 0{,}5$). Com $\sigma_N = 1{,}0$ (configurações A e C), o GNG tem erro de quantização menor que o SOM em todos os tamanhos e nas três imagens (por exemplo, `astronaut` com 16 neurônios: 0,0607 no GNG contra 0,0710 no SOM A).

SOM × GNG: preservação topológica. Aqui a diferença é grande: o erro topológico do GNG ficou entre 0,0002 e 0,02, enquanto o do SOM ficou entre 0,008 e 0,23 – tipicamente de 10 a 100 vezes maior. No GNG as arestas são criadas justamente entre o 1º e o 2º BMU (regra de Hebb competitiva), então a topologia da rede acompanha a distribuição real das cores. No SOM a topologia é imposta: uma grade 2D precisa se "dobrar" para cobrir uma nuvem de cores em 3D, e cada dobra cria regiões em que o 2º BMU fica longe na grade.

O compromisso entre os dois erros no SOM. A configuração B mostra bem esse compromisso. Com $\sigma_N = 0{,}5$, no fim do treino a vizinhança efetiva quase desaparece e o batch SOM passa a se comportar como um k-means: cada neurônio se ajusta ao seu grupo de pixels sem ser puxado pelos vizinhos. Isso reduz o erro de quantização, mas desorganiza o mapa – B teve o *maior* erro topológico em quase todos os casos. Com $\sigma_N = 1{,}0$, o mapa fica mais ordenado, mas os neurônios são puxados para regiões intermediárias entre grupos de cor, o que piora a quantização. Ou seja, no SOM não dá para ter os dois ao mesmo tempo; o GNG chega ao mesmo erro de quantização sem abrir mão da topologia.

Outros hiperparâmetros.

- **SOM, σ_0 menor (config. C):** começar com uma vizinhança menor ($\sigma_0 = L/4$) piorou o erro de quantização na maioria dos casos e, em geral, também o erro topológico: com pouca vizinhança no início, a grade não chega a se "desdobrar" sobre todas as cores antes de começar o ajuste fino, e algumas torções ficam congeladas. Um σ_0 grande é importante para a organização global do mapa.
- **GNG, taxas menores (config. B):** com o treino de 2 épocas, as taxas pequenas ($\varepsilon_b = 0{,}05$) deram o menor erro de quantização em quase todos os casos: depois que a rede termina de crescer, passos menores deixam os neurônios se acomodarem com mais precisão, em vez de ficarem "pulando" entre pixels.
- **GNG, λ maior (config. C):** inserir neurônios com menos frequência deu, em geral, o menor erro topológico, porque cada neurônio novo tem mais tempo para se encaixar e formar arestas corretas antes da próxima inserção.

Uso dos neurônios. Quase todos os neurônios viraram cor de algum pixel; a única exceção relevante foi o GNG B com 256 neurônios na `astronaut`, com 251 cores usadas (alguns neurônios ficaram em regiões sem pixels depois do ajuste fino).

Outras imagens. Em `coffee` e `chelsea` (Apêndice A) as mesmas tendências se repetem: o erro cai com o tamanho da rede, SOM (config. B) e GNG empatam na qualidade da reconstrução, o GNG tem erro topológico muito menor, e no SOM a config. B é a de menor erro de quantização e maior erro topológico.

5 Conclusão

As duas redes conseguem comprimir a paleta de dezenas de milhares de cores para 16–256 cores mantendo boa qualidade visual, e com 256 neurônios o resultado é praticamente indistinguível da imagem original. Na qualidade da reconstrução, o SOM só alcança o GNG quando a vizinhança final é reduzida, e aí perde a organização do mapa. O GNG obtém o mesmo erro de quantização preservando a topologia muito melhor, por isso é a escolha mais adequada para a compressão em si. O SOM, por outro lado, entrega uma paleta organizada em uma grade 2D (cores parecidas lado a lado), útil quando se quer visualizar ou indexar o espaço de cores. Em ambos, os hiperparâmetros controlam o equilíbrio entre representar bem os dados (EQ) e preservar a vizinhança (ET).

A Resultados nas outras imagens

Modelo	Rede	Config.	Cores	EQ	ET	MSE	PSNR (dB)	Tempo (s)
SOM	4x4	A	16	0.0586	0.0084	1.58e-03	28.02	4.7
SOM	4x4	B	16	0.0498	0.1070	1.07e-03	29.71	6.1
SOM	4x4	C	16	0.0661	0.1977	2.39e-03	26.21	5.3
SOM	8x8	A	64	0.0273	0.1633	3.52e-04	34.52	20.5
SOM	8x8	B	64	0.0251	0.2283	2.81e-04	35.49	22.3
SOM	8x8	C	64	0.0279	0.1678	3.73e-04	34.28	23.1
SOM	16x16	A	256	0.0146	0.0945	1.06e-04	39.69	78.6
SOM	16x16	B	256	0.0137	0.1315	8.74e-05	40.52	75.6
SOM	16x16	C	256	0.0146	0.0938	1.05e-04	39.74	76.5
GNG	16 neur.	A	16	0.0533	0.0021	1.23e-03	29.09	16.2
GNG	16 neur.	B	16	0.0506	0.0002	1.09e-03	29.62	17.3
GNG	16 neur.	C	16	0.0523	0.0010	1.17e-03	29.32	18.7
GNG	64 neur.	A	64	0.0254	0.0130	2.96e-04	35.27	19.2
GNG	64 neur.	B	64	0.0245	0.0086	2.68e-04	35.71	18.3
GNG	64 neur.	C	64	0.0256	0.0040	3.03e-04	35.16	16.7
GNG	256 neur.	A	256	0.0143	0.0117	9.76e-05	40.05	21.1
GNG	256 neur.	B	256	0.0142	0.0098	9.16e-05	40.32	20.1
GNG	256 neur.	C	256	0.0144	0.0070	9.93e-05	39.99	19.2

Tabela 6: Imagem `coffee`.

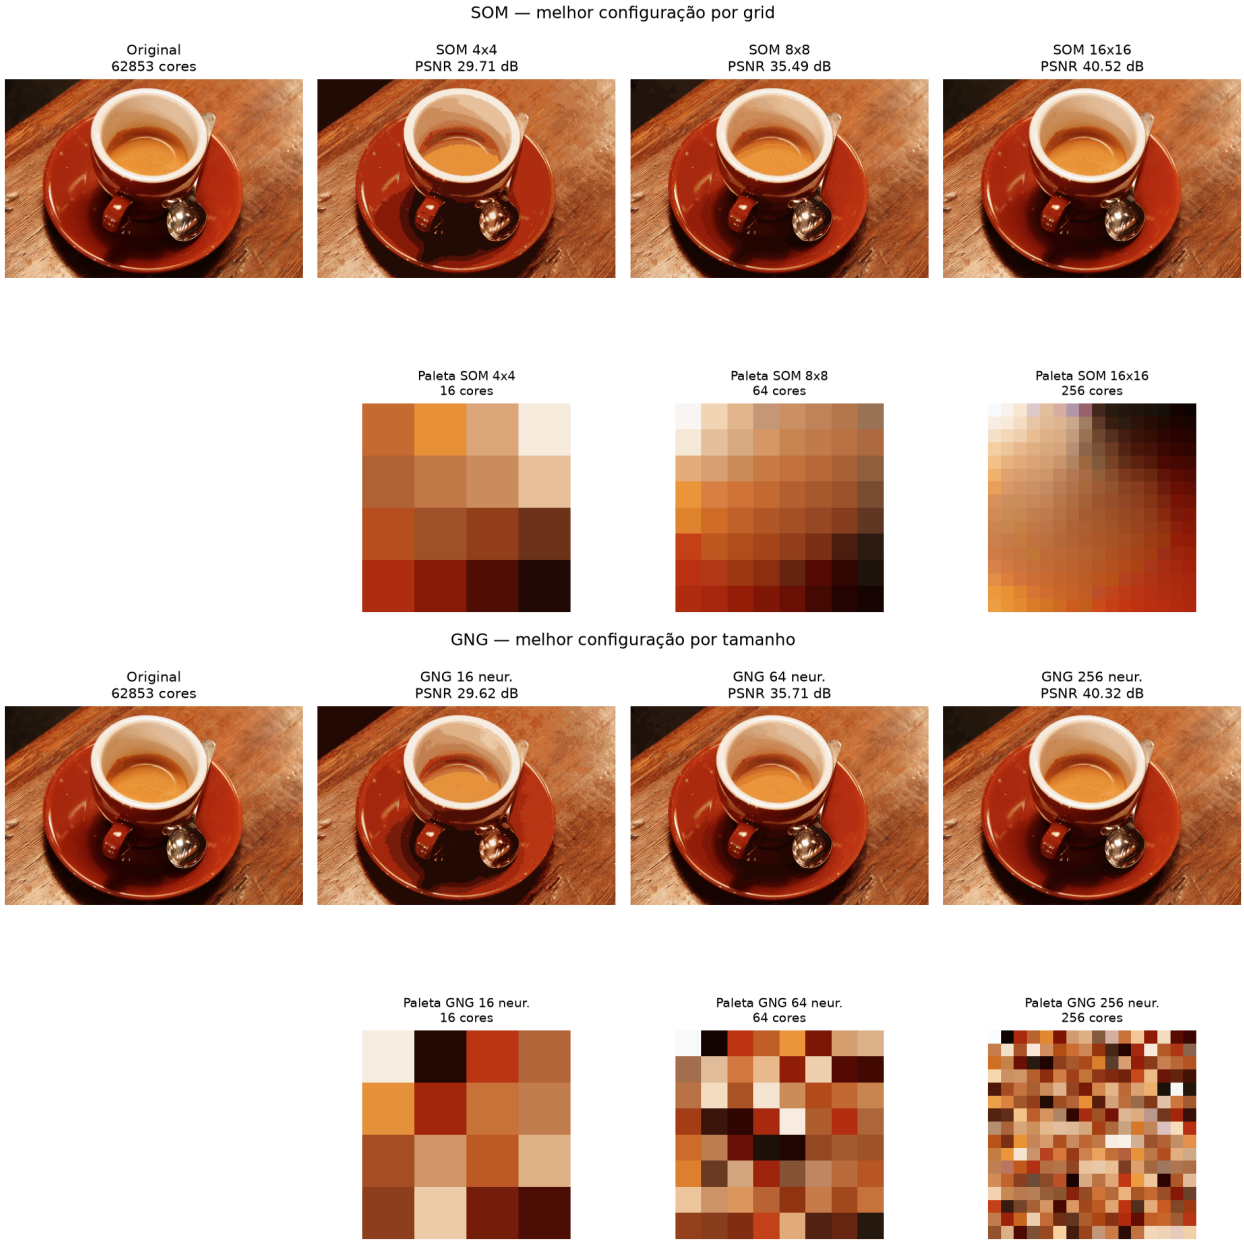


Figura 6: Reconstruções da imagem `coffee`.

Modelo	Rede	Config.	Cores	EQ	ET	MSE	PSNR (dB)	Tempo (s)
SOM	4x4	A	16	0.0484	0.0368	1.18e-03	29.22	6.2
SOM	4x4	B	16	0.0441	0.1558	8.03e-04	30.94	6.5
SOM	4x4	C	16	0.0501	0.0555	1.33e-03	28.74	6.6
SOM	8x8	A	64	0.0265	0.0517	3.42e-04	34.64	22.3
SOM	8x8	B	64	0.0240	0.1859	2.46e-04	36.07	23.2
SOM	8x8	C	64	0.0264	0.1273	3.51e-04	34.54	24.9
SOM	16x16	A	256	0.0154	0.1031	1.14e-04	39.40	76.2
SOM	16x16	B	256	0.0144	0.1708	9.16e-05	40.32	75.2
SOM	16x16	C	256	0.0154	0.1265	1.12e-04	39.47	74.7
GNG	16 neur.	A	16	0.0456	0.0050	9.21e-04	30.35	17.0
GNG	16 neur.	B	16	0.0443	0.0061	8.29e-04	30.82	19.4
GNG	16 neur.	C	16	0.0465	0.0003	9.52e-04	30.21	18.4
GNG	64 neur.	A	64	0.0248	0.0193	2.65e-04	35.74	18.3
GNG	64 neur.	B	64	0.0242	0.0043	2.43e-04	36.12	16.8
GNG	64 neur.	C	64	0.0249	0.0039	2.66e-04	35.73	16.8
GNG	256 neur.	A	256	0.0149	0.0195	9.40e-05	40.21	20.7
GNG	256 neur.	B	256	0.0148	0.0126	8.88e-05	40.45	19.9
GNG	256 neur.	C	256	0.0149	0.0094	9.66e-05	40.09	20.1

Tabela 7: Imagem `chelsea`.

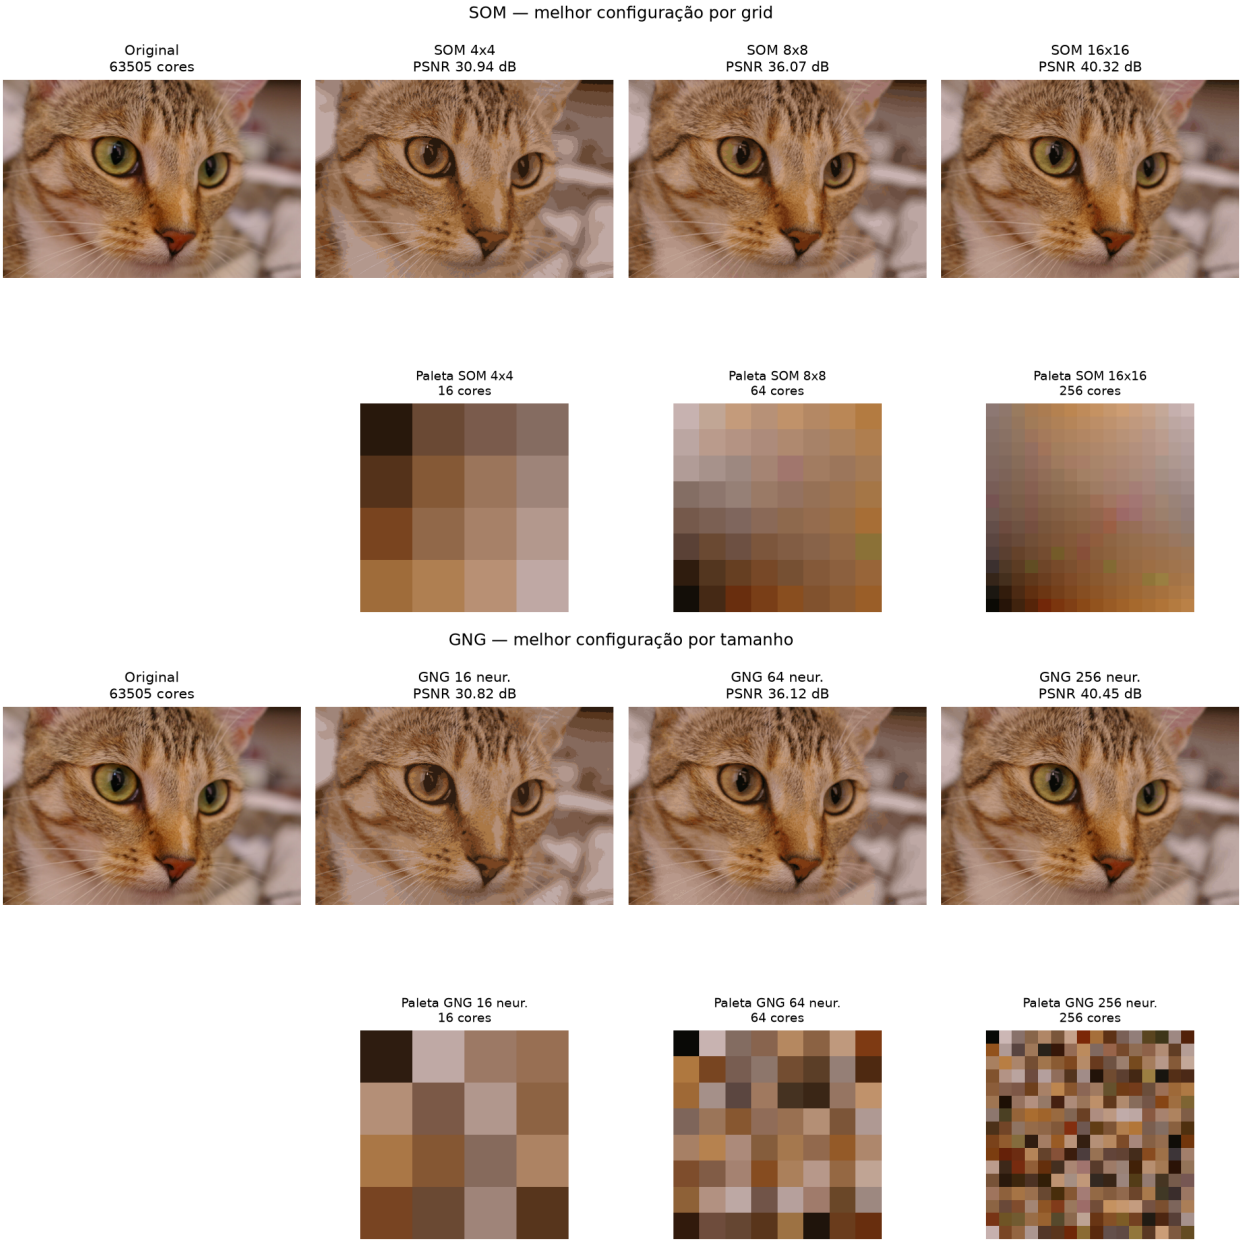


Figura 7: Reconstruções da imagem `chelsea`.