Projeto 2: Quantização de Cores com Redes SOM e GNG

Disciplina: Introdução às Redes Neurais Artificiais

Autora: Aline Breda Kuster (RA: 168.495)

Repositório: `https://github.com/aline-kuster/Proj2`

---

1 Objetivo

Reduzir drasticamente a paleta de cores de uma imagem (compressão) usando aprendizado competitivo, comparando o SOM (topologia fixa em uma grade 2D) com o GNG (topologia que cresce e se adapta aos dados), e avaliando as redes pelo erro de quantização e pelo erro topológico.

2 Metodologia

2.1 Extração

Cada imagem é carregada em RGB e redimensionada (filtro Lanczos, mantendo a proporção) para no máximo 450 pixels de lado ($\approx 135\,000$ pixels). Todos os pixels são extraídos e normalizados, e cada pixel vira uma amostra $\mathbf{x} = (R, G, B) \in [0, 1]^3$: a imagem passa a ser um conjunto de dados 3D. Foram usadas cinco imagens com distribuições de cor bem diferentes:

Imagem	Conteúdo	Cores distintas
`por_do_sol`	degradê laranja e silhuetas escuras	36 390
`campo`	céu azul, nuvens brancas e grama	38 124
`praia`	céu, mar verde-azulado e areia	61 180
`tintas`	tintas de todas as cores (arco-íris)	92 991
`arara`	arara azul e amarela, fundo desfocado	78 855

Tabela 1: Imagens utilizadas.

2.2 Treinamento

SOM. Grades 4×4, 8×8 e 16×16, treinadas com a biblioteca **XPySom** por 100 épocas, com pesos iniciais sorteados entre os pixels e vizinhança gaussiana cujo raio σ decai exponencialmente de σ_0 até σ_N. A XPySom usa o *batch SOM*, em que cada peso é substituído pela média dos pixels ponderada pela vizinhança; nessa conta a taxa de aprendizado se cancela, por isso o ajuste foi feito no raio σ. O projeto também inclui uma implementação própria do SOM online (`-som-impl propria`).

GNG. Implementação própria (Fritzke, 1995) com 16, 64 e 256 neurônios. A rede começa com 2 neurônios; a cada pixel, o vencedor s_1 e seus vizinhos se movem em direção à amostra (taxas ε_b e ε_n), a aresta s_1–s_2 é criada ou renovada e arestas mais velhas que $a_{\max}$ são removidas. A cada λ iterações nasce um neurônio entre o de maior erro acumulado e seu vizinho de maior erro ($\alpha = 0{,}5$, $d = 0{,}995$). O treino dura 2 épocas ($\approx 270\,000$ iterações).

2.3 Ajuste de hiperparâmetros

Para cada tamanho de rede foram testadas três configurações; nos resultados é usada a de menor erro de quantização.

Config.	SOM (XPySom)	GNG
A	$\sigma_0 = L/2$, $\sigma_N = 1{,}0$	$\varepsilon_b = 0{,}2$, $\varepsilon_n = 0{,}006$, $\lambda = 100$, $a_{\max} = 50$
B	$\sigma_0 = L/2$, $\sigma_N = 0{,}5$	$\varepsilon_b = 0{,}05$, $\varepsilon_n = 0{,}0006$, $\lambda = 100$, $a_{\max} = 50$
C	$\sigma_0 = L/4$, $\sigma_N = 1{,}0$	$\varepsilon_b = 0{,}2$, $\varepsilon_n = 0{,}006$, $\lambda = 300$, $a_{\max} = 100$

Tabela 2: Configurações testadas (L = lado da grade do SOM).

2.4 Inferência e reconstrução

Para cada pixel encontra-se o neurônio vencedor (BMU), $c(\mathbf{x}) = \arg\min_i \|\mathbf{x} - \mathbf{w}_i\|$, e a cor do pixel é substituída pelos pesos $\mathbf{w}_{c(\mathbf{x})}$. A matriz da imagem ($H \times W \times 3$) é então reconstruída, salva e exibida na tela.

2.5 Métricas

- **Erro de quantização (EQ):** distância média entre cada pixel e a cor do seu BMU.
- **Erro topológico (ET):** fração de pixels cujo 1º e 2º BMU *não* são vizinhos na rede (no SOM, adjacentes na grade; no GNG, ligados por aresta).
- **PSNR (dB):** qualidade visual da reconstrução, $10 \log_{10}(255^2/\text{MSE})$.
- **Cores usadas:** quantos neurônios viraram a cor de algum pixel.

3 Resultados

As Tabelas 3 e 4 mostram a melhor configuração de cada rede nas cinco imagens; a Figura 1 e a Tabela 5 comparam os dois modelos.

Imagem	Grade	Config.	EQ	ET	PSNR (dB)	Cores
`por_do_sol`	4x4	B	0,0307	0,0000	33,39	16
`por_do_sol`	8x8	B	0,0158	0,1510	39,01	64
`por_do_sol`	16x16	B	0,0086	0,2063	44,23	255
`campo`	4x4	B	0,0421	0,0068	30,58	15
`campo`	8x8	B	0,0183	0,0553	37,28	62
`campo`	16x16	B	0,0098	0,1652	43,12	254
`praia`	4x4	B	0,0521	0,0466	29,16	16
`praia`	8x8	B	0,0257	0,0661	35,14	64
`praia`	16x16	B	0,0145	0,0697	39,95	256
`tintas`	4x4	B	0,1075	0,1017	22,84	16
`tintas`	8x8	B	0,0534	0,0901	28,93	64
`tintas`	16x16	B	0,0295	0,1264	33,84	245
`arara`	4x4	B	0,0730	0,0234	26,21	16
`arara`	8x8	B	0,0373	0,0198	31,85	64
`arara`	16x16	B	0,0213	0,1770	36,44	256
Média	4x4	–	0,0611	0,0357	28,44	15,8
Média	8x8	–	0,0301	0,0765	34,44	63,6
Média	16x16	–	0,0167	0,1489	39,51	253,2

Tabela 3: Resultados do SOM.

Imagem	Neurônios	Config.	EQ	ET	PSNR (dB)	Cores
`por_do_sol`	16	B	0,0308	0,0011	33,31	16
`por_do_sol`	64	B	0,0156	0,0016	39,29	64
`por_do_sol`	256	C	0,0085	0,0041	44,12	256
`campo`	16	B	0,0395	0,0028	31,17	16
`campo`	64	A	0,0178	0,0030	37,86	64
`campo`	256	A	0,0101	0,0089	43,01	256
`praia`	16	B	0,0517	0,0036	29,29	16
`praia`	64	B	0,0257	0,0080	35,36	64
`praia`	256	A	0,0152	0,0090	39,80	256
`tintas`	16	B	0,1064	0,0047	23,08	16
`tintas`	64	B	0,0539	0,0040	28,96	64
`tintas`	256	B	0,0296	0,0090	34,08	256
`arara`	16	B	0,0751	0,0119	26,04	16
`arara`	64	B	0,0376	0,0044	31,77	64
`arara`	256	A	0,0221	0,0140	36,10	256
Média	16	–	0,0607	0,0048	28,58	16,0
Média	64	–	0,0301	0,0042	34,65	64,0
Média	256	–	0,0171	0,0090	39,42	256,0

Tabela 4: Resultados do GNG.

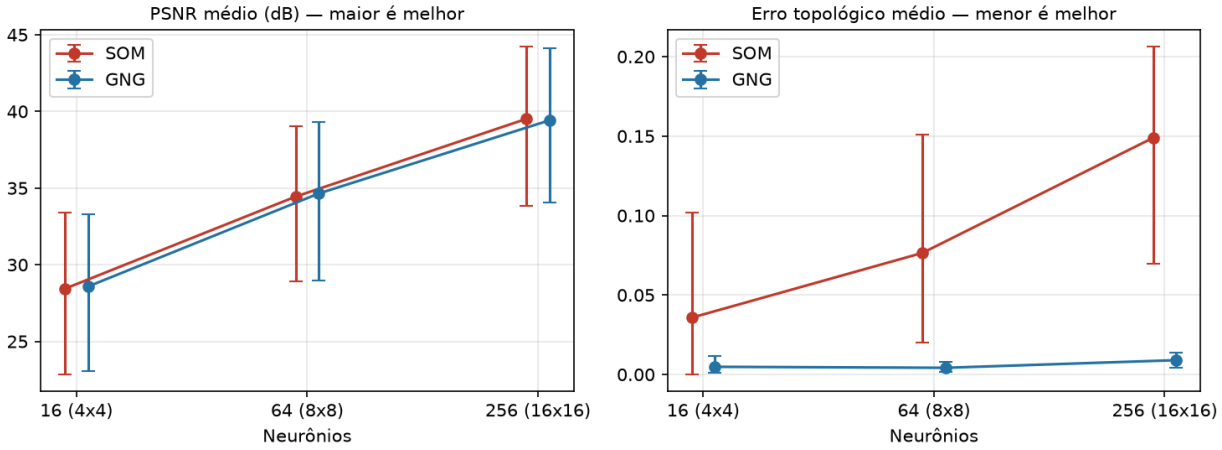


Figura 1: Média das cinco imagens (as barras vão do pior ao melhor caso). Na qualidade (PSNR) as curvas praticamente se sobrepõem; no erro topológico o GNG fica muito abaixo do SOM.

	16 protótipos		64 protótipos		256 protótipos	
Imagem	SOM	GNG	SOM	GNG	SOM	GNG
PSNR (dB) – quanto maior, melhor						
`por_do_sol`	33,39	33,31	39,01	39,29	44,23	44,12
`campo`	30,58	31,17	37,28	37,86	43,12	43,01
`praia`	29,16	29,29	35,14	35,36	39,95	39,80
`tintas`	22,84	23,08	28,93	28,96	33,84	34,08
`arara`	26,21	26,04	31,85	31,77	36,44	36,10
Média	**28,44**	**28,58**	**34,44**	**34,65**	**39,51**	**39,42**
Erro topológico – quanto menor, melhor						
`por_do_sol`	0,0000	0,0011	0,1510	0,0016	0,2063	0,0041
`campo`	0,0068	0,0028	0,0553	0,0030	0,1652	0,0089
`praia`	0,0466	0,0036	0,0661	0,0080	0,0697	0,0090
`tintas`	0,1017	0,0047	0,0901	0,0040	0,1264	0,0090
`arara`	0,0234	0,0119	0,0198	0,0044	0,1770	0,0140
Média	**0,0357**	**0,0048**	**0,0765**	**0,0042**	**0,1489**	**0,0090**

Tabela 5: Comparação direta SOM × GNG, com o mesmo número de neurônios.

Modelo	Config.	EQ médio	ET médio	Menor EQ	Menor ET
SOM	A	0,0413	0,0526	0/15	10/15
SOM	B	0,0360	0,0870	15/15	2/15
SOM	C	0,0425	0,1045	0/15	3/15
GNG	A	0,0373	0,0069	4/15	1/15
GNG	B	0,0362	0,0052	10/15	5/15
GNG	C	0,0375	0,0038	1/15	9/15

Tabela 6: Efeito das configurações A, B e C: médias nas 15 combinações (5 imagens × 3 tamanhos) e em quantas delas cada configuração teve o menor erro.

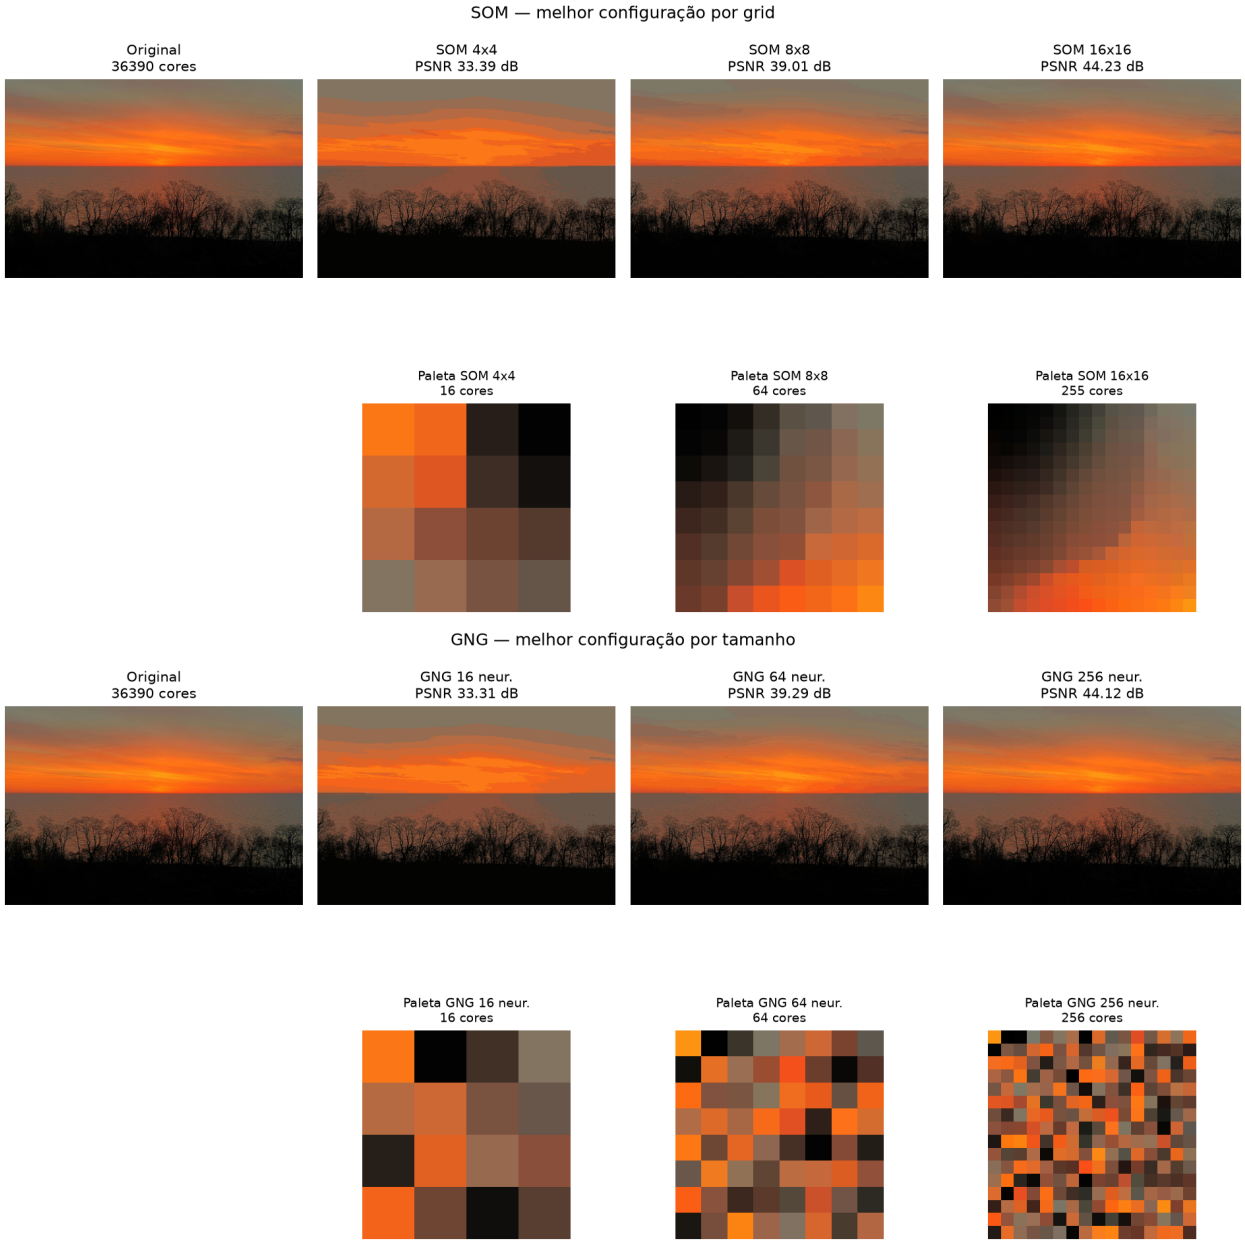
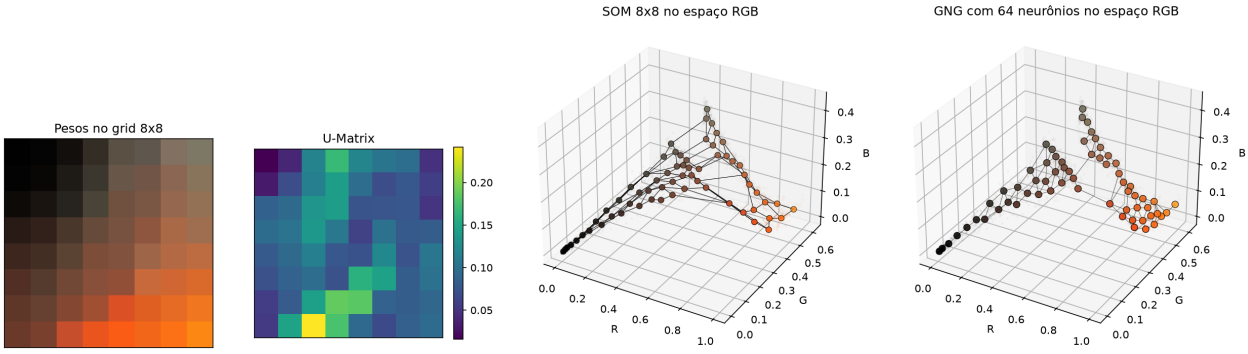


Figura 2: `por_do_sol`: reconstruções com 16, 64 e 256 cores e as paletas aprendidas. Na paleta do SOM as cores estão na posição da grade (degradê); na do GNG, na ordem de inserção.



(a) SOM 8×8: pesos na grade e U-Matrix. (b) SOM 8×8 no espaço RGB. (c) GNG com 64 neurônios.

Figura 3: Topologia aprendida (`por_do_sol`): a grade do SOM precisa se dobrar para cobrir as cores, enquanto o grafo do GNG segue a forma da nuvem de pixels.

4 Discussão

Tamanho da rede. Nos dois modelos, aumentar o número de neurônios reduz o erro de quantização aproximadamente pela metade a cada salto, e o PSNR médio sobe cerca de 5–6 dB ($\approx 28{,}5 \rightarrow 34{,}5 \rightarrow 39{,}5$ dB). Com 16 cores os degradês viram *faixas* (posterização); com 256 a imagem fica praticamente igual à original (Figura 2).

Dificuldade de cada imagem. Depende de quão espalhadas estão as cores no espaço RGB. O `por_do_sol` foi a mais fácil (44 dB com 256 cores), pois suas cores formam quase uma curva do preto ao laranja. As `tintas` foram a mais difícil (34 dB), com matizes saturados espalhados por todo o cubo RGB.

SOM × GNG. Na qualidade os dois praticamente empatam: a diferença de PSNR nunca passa de 0,6 dB e as médias ficam a menos de 0,25 dB (Tabela 5). Já no erro topológico a diferença é grande: o do SOM é, em média, de 7 a 18 vezes o do GNG e cresce com o tamanho da grade (Figura 1). No GNG as arestas ligam exatamente o 1º e o 2º BMU de cada pixel, então a topologia acompanha os dados; no SOM a grade 2D precisa se dobrar para cobrir uma nuvem 3D, e cada dobra gera erro topológico (Figura 3). Em troca, o SOM entrega uma paleta organizada, com cores parecidas lado a lado.

O compromisso no SOM. O empate em qualidade só acontece porque a melhor configuração do SOM foi sempre a B ($\sigma_N = 0{,}5$, Tabela 6). Com a vizinhança final pequena, os neurônios ficam livres para se ajustar às cores (o SOM vira quase um k-means), o que reduz o EQ mas desorganiza o mapa: B teve o maior ET médio entre A e B. Com $\sigma_N = 1{,}0$ (A) o mapa fica mais ordenado, mas o EQ piora e o GNG passa a ser melhor em todos os casos. Começar com vizinhança pequena (C) foi o pior nos dois erros, pois a grade não chega a se desdobrar no início do treino.

Hiperparâmetros do GNG. Taxas menores (B) deram o menor EQ na maioria dos casos, pois os neurônios se acomodam com mais precisão depois que a rede para de crescer. Inserir neurônios com menos frequência (C, λ maior) deu o menor ET, pois cada neurônio novo tem tempo de se encaixar antes do próximo.

Uso dos neurônios. Quase todos os neurônios viraram a cor de algum pixel. As poucas exceções (por exemplo, o SOM 16×16 usou 245 cores nas `tintas`) são neurônios que ficaram em regiões vazias do espaço de cores, entre grupos de pixels.

5 Conclusão

As duas redes comprimem a paleta de dezenas de milhares de cores para 16–256 cores com boa qualidade, e com 256 neurônios o resultado é praticamente indistinguível da original. O GNG é a melhor escolha para a compressão em si, pois atinge a mesma fidelidade preservando a topologia; o SOM só alcança essa fidelidade abrindo mão da organização do mapa, mas é útil quando se quer uma paleta ordenada e fácil de visualizar. Em ambos, os hiperparâmetros controlam o equilíbrio entre representar bem as cores (EQ) e preservar a vizinhança (ET).

A Reconstruções das outras imagens

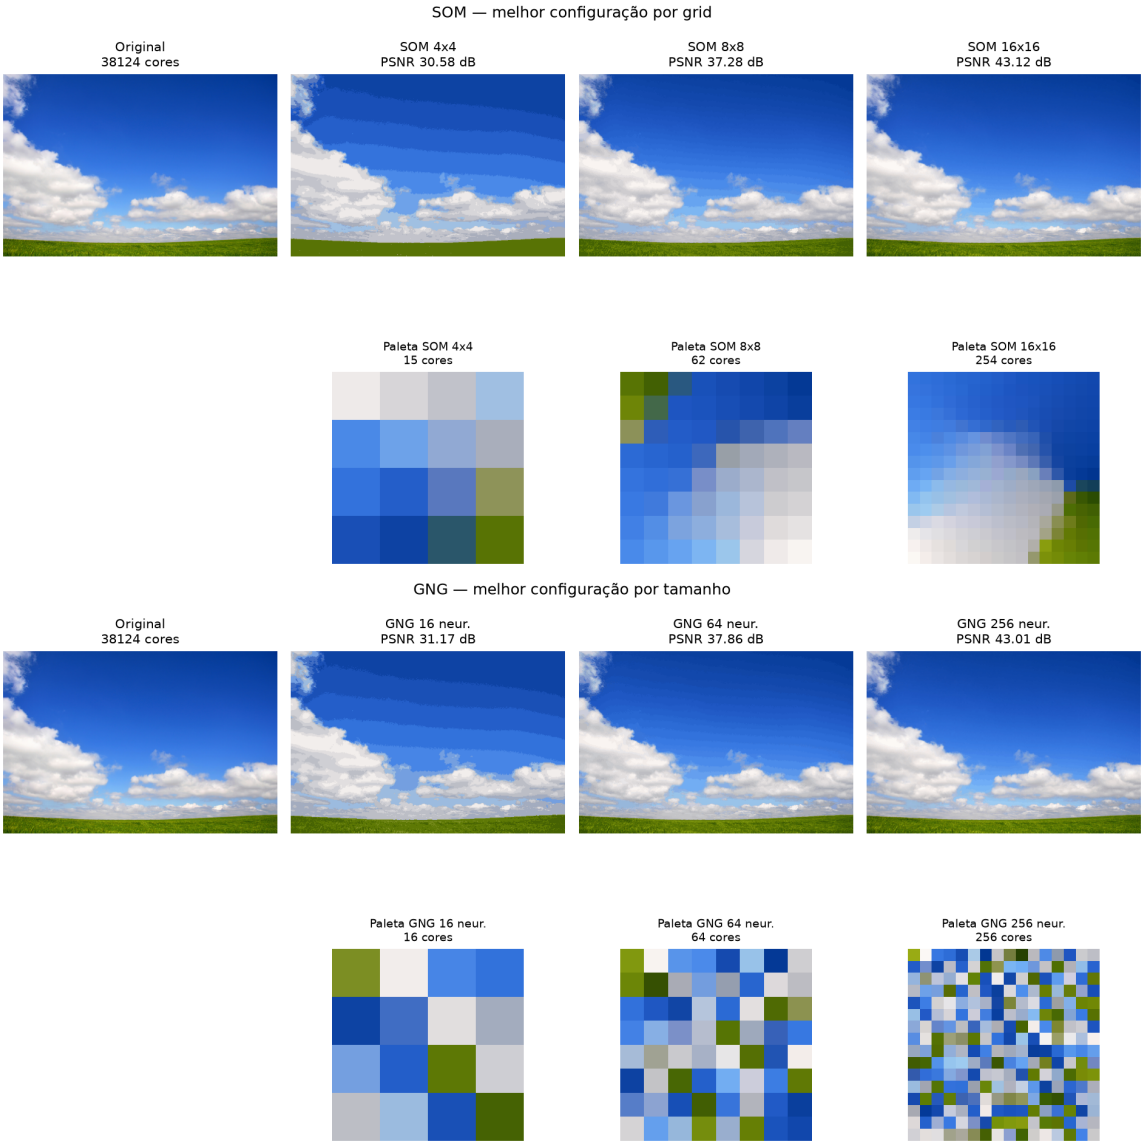


Figura 4: `campo` (acima SOM, abaixo GNG).

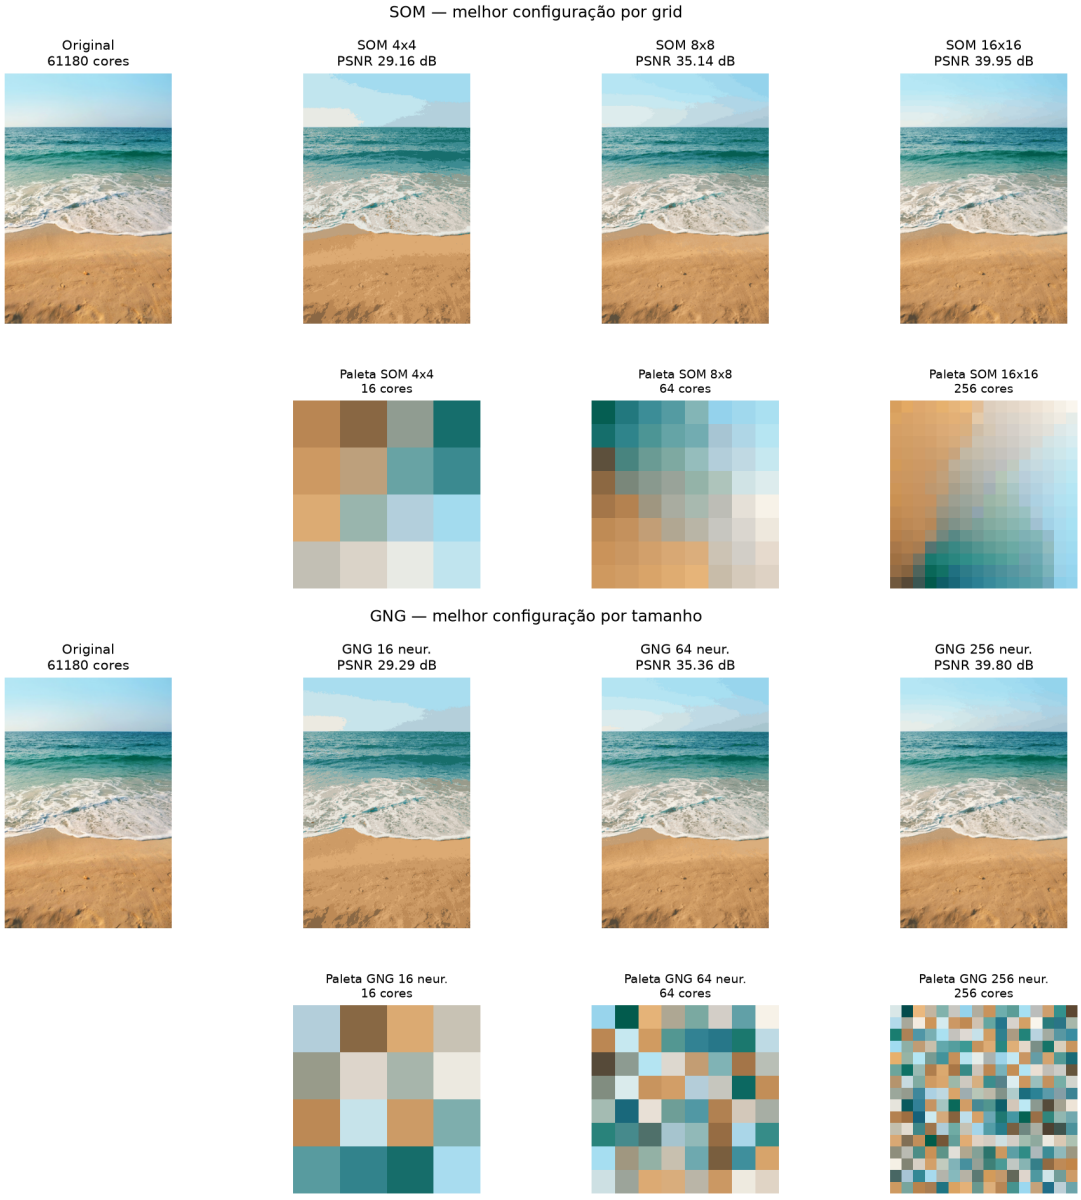


Figura 5: `praia` (acima SOM, abaixo GNG).

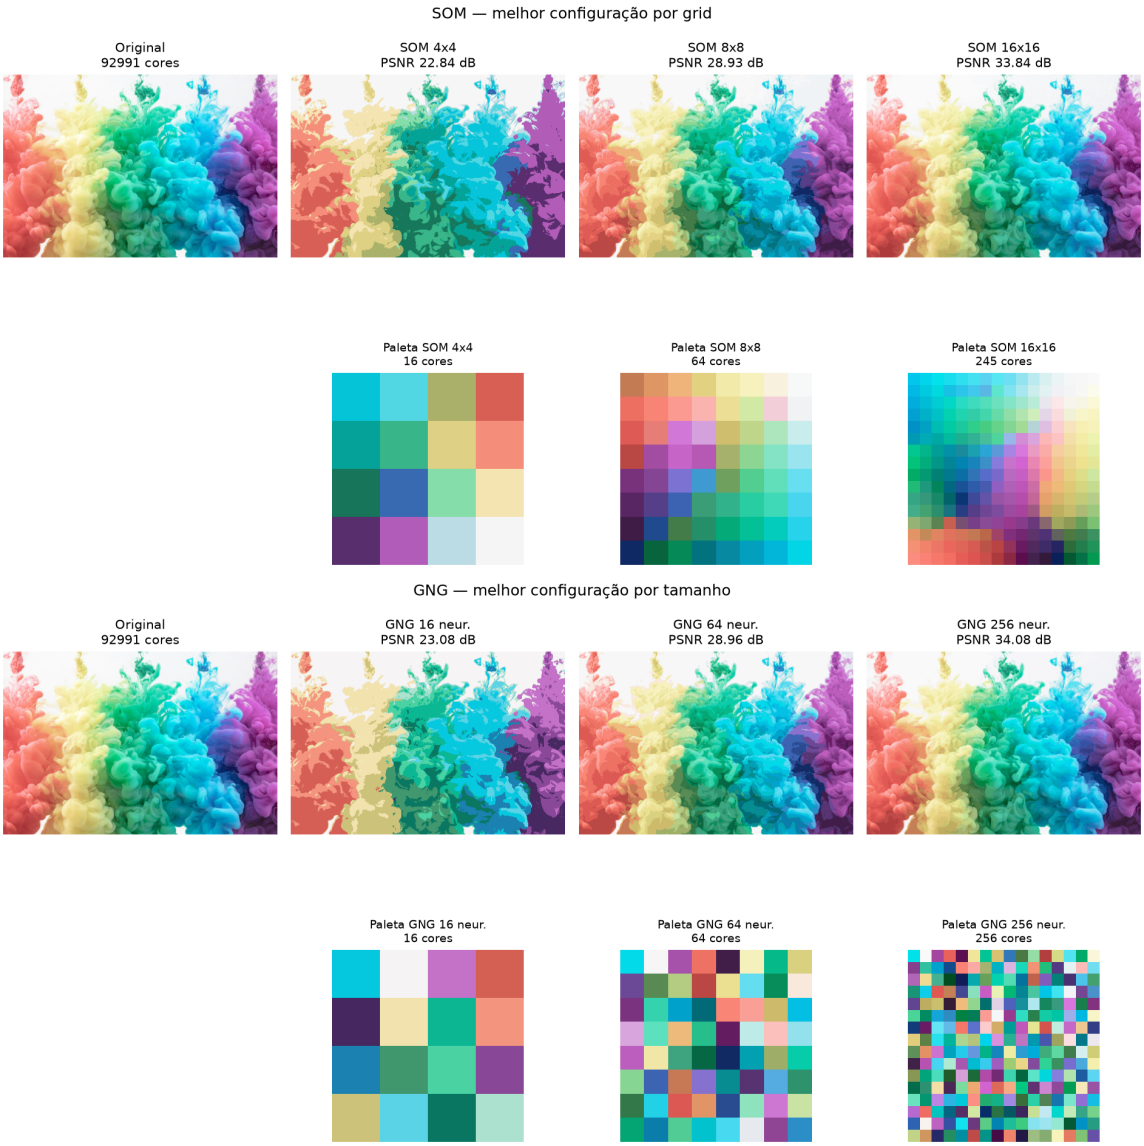


Figura 6: `tintas` (acima SOM, abaixo GNG).

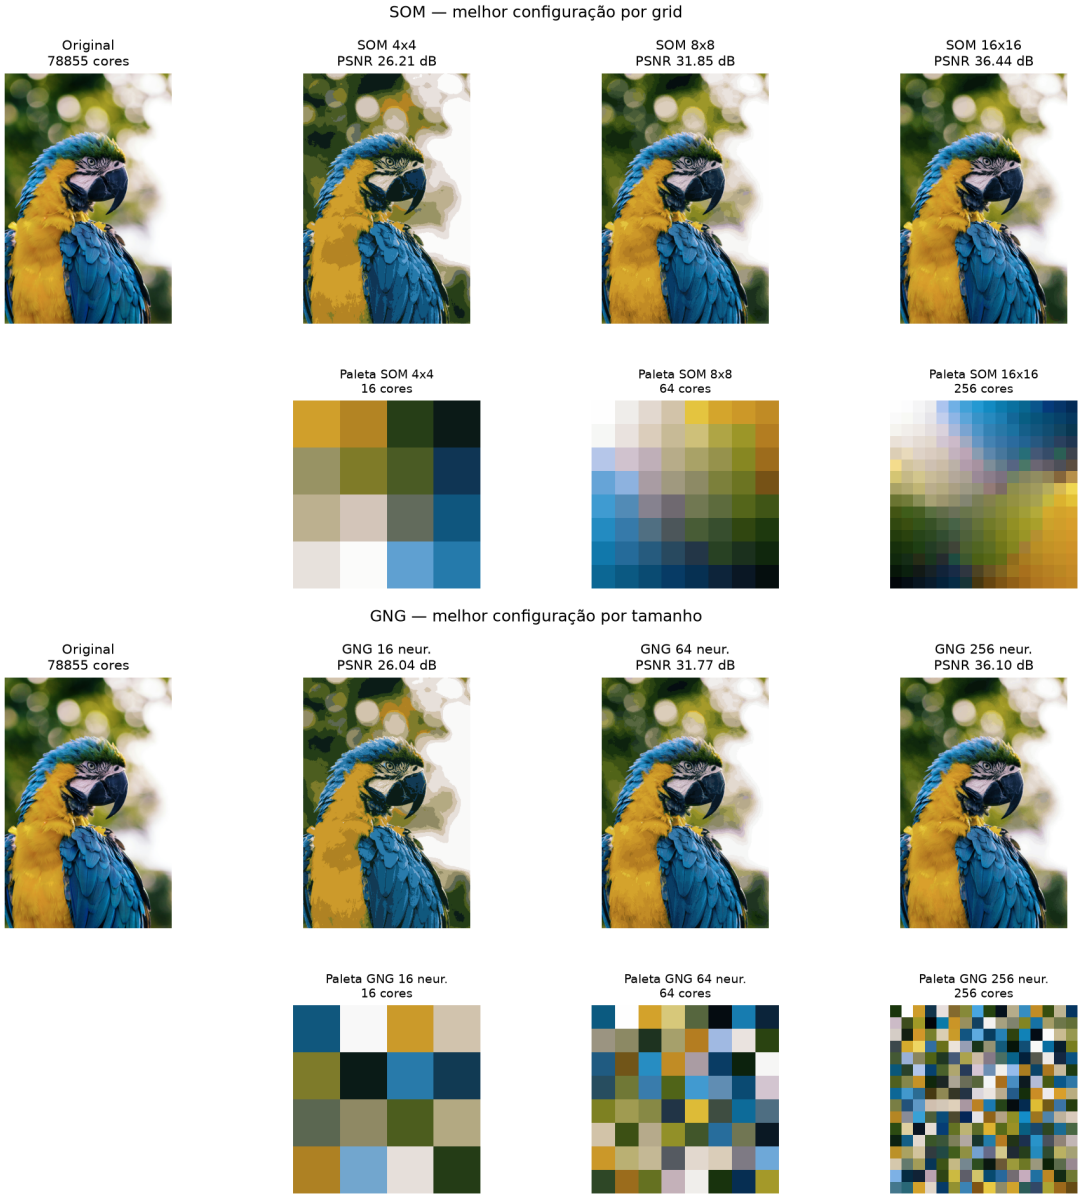


Figura 7: `arara` (acima SOM, abaixo GNG).